

Машинное обучение: как найти то, что скрыто в данных?

Введение

*Четвертая технологическая революция строится на вездесущем мобильном Интернете, искусственном интеллекте и **машинном обучении** (2016).*

Клаус Мартин Шваб
президент Всемирного экономического форума



Программа курса

- 5 лекций по теории машинного обучения и 5 практических занятий в среде KNIME

ЧАСТЬ 1

Введение в ML

ТЕОРИЯ

Основные понятия ML.
Этапы решения ML-задач.
Типы задач и примеры приложений.

ПРАКТИКА

Знакомство с KNIME:
интерфейс, первый
workflow, загрузка данных,
визуализация.

ЧАСТЬ 2

Регрессия

ТЕОРИЯ

Постановка задачи
регрессии. Линейная и
полиномиальная
регрессии. Обучение
модели и оценка качества.

ПРАКТИКА

Разбор задачи по
прогнозированию
рыночной стоимости
квартиры.

ЧАСТЬ 3

Поиск шаблонов

ТЕОРИЯ

Постановка задачи поиска
частых наборов и
ассоциативных правил.
Алгоритм Apriori.

ПРАКТИКА

Разбор задачи по анализу
покупательской корзины.

ЧАСТЬ 4

Классификация

ТЕОРИЯ

Постановка задачи
классификации. Деревья
решений. Метрики
качества.

ПРАКТИКА

Разбор задачи по
прогнозированию дохода.

ЧАСТЬ 5

Кластеризация

ТЕОРИЯ

Постановка задачи
кластеризации. Алгоритмы
k-means и k-medoids.
Оценка качества
кластеризации.

ПРАКТИКА

Разбор задачи по
сегментации клиентов.

**ИНСТРУМЕНТ KNIME**

мощная открытая платформа для Data Science, анализа данных и машинного обучения, которая работает по принципу no-code/low-code.

URL для скачивания: <https://www.knime.com/downloads>

Содержание

- **Понятие машинного обучения**
- Основные определения и обозначения
- Этапы решения задачи машинного обучения
- Типы машинного обучения
 - основные задачи машинного обучения
 - примеры прикладных задач


Что такое искусственный интеллект, машинное и глубокое обучение

- **Искусственный интеллект (artificial intelligence, AI)** – область компьютерной науки, занимающаяся созданием систем, способных выполнять задачи, требующие интеллектуальных способностей человека.
- **Машинное обучение (machine learning, ML)** – класс методов AI, характерной чертой которых является не прямое решение задачи, а обучение модели на большом количестве входных данных для выявления в них закономерностей.
- **Глубокое обучение (deep learning, DL)** – раздел ML, ориентированный на создание и обучение искусственных нейронных сетей, способных автоматически извлекать важные и сложные характеристики из входных данных.




Что такое искусственный интеллект, машинное и глубокое обучение

- **Искусственный интеллект (artificial intelligence, AI)** – область компьютерной науки, занимающаяся созданием систем, способных выполнять задачи, требующие интеллектуальных способностей человека.
- **Машинное обучение (machine learning, ML)** – класс методов AI, характерной чертой которых является не прямое решение задачи, а обучение модели на большом количестве входных данных для выявления в них закономерностей.
- **Глубокое обучение (deep learning, DL)** – раздел ML, ориентированный на создание и обучение искусственных нейронных сетей, способных автоматически извлекать важные и сложные характеристики из входных данных.



Традиционное программирование vs Машинное обучение



Пример:

Решение квадратного уравнения $ax^2 + bx + c = 0$

- **Традиционное программирование:** обучение компьютера решать уравнение по правилам и инструкциям


```
1 def solve_quadratic_equation(a, b, c):
2     discriminant = b**2 - 4*a*c
3     if discriminant > 0:
4         x1 = (-b + sqrt(discriminant)) / (2*a)
5         x2 = (-b - sqrt(discriminant)) / (2*a)
6         return x1, x2
7     elif discriminant == 0:
8         x1 = -b / (2*a)
9         return x1
10    else:
11        return None
```

- **Машинное обучение:** компьютеру показывают много уравнений (их коэффициенты и корни), он анализирует и пытается решить уравнение на основе своего опыта

Уравнение	Коэффициенты (данные)	Корни (ответы)
$4x^2 - 16x + 10 = 0$	$a = 4, b = -16, c = 10$	$x_1 = 0.78, x_2 = 3.22$
$-5x^2 - 12x + 3 = 0$	$a = -5, b = -12, c = 3$	$x_1 = 0.23, x_2 = -2.63$
$x^2 - 30 = 0$	$a = 1, b = 0, c = -30$	$x_1 = -5.48, x_2 = 5.48$
...	...	...

Что такое искусственный интеллект, машинное и глубокое обучение

- **Искусственный интеллект (artificial intelligence, AI)** – область компьютерной науки, занимающаяся созданием систем, способных выполнять задачи, требующие интеллектуальных способностей человека.
- **Машинное обучение (machine learning, ML)** – класс методов AI, характерной чертой которых является не прямое решение задачи, а обучение модели на большом количестве входных данных для выявления в них закономерностей.
- **Глубокое обучение (deep learning, DL)** – раздел ML, ориентированный на создание и обучение искусственных нейронных сетей, способных автоматически извлекать важные и сложные характеристики из входных данных.



Содержание

- Понятие машинного обучения
- **Основные определения и обозначения**
- Этапы решения задачи машинного обучения
- Типы машинного обучения
 - основные задачи машинного обучения
 - примеры прикладных задач

Выборка данных

- Выборка данных (набор данных, dataset)** – конечный набор прецедентов (объектов, образцов) некоторой предметной области из генеральной совокупности:

$$Z = \{z^{(i)}\}_{i=1}^N,$$

где N – количество прецедентов в выборке

- Прецедент (instance)** – абстрактная сущность, описываемая некоторым набором признаков:

$$z^{(i)} = (f_1(z^{(i)}), \dots, f_P(z^{(i)})), \quad z^{(i)} \in Z,$$

где $f_j(z^{(i)})$ – значение j -го признака у объекта $z^{(i)}$, $1 \leq j \leq P$, P – количество признаков

- Признак, атрибут (feature, attribute)** – результат измерения некоторой характеристики объекта

Набор данных Census Income*

(данные о результатах переписи населения 1994 г. в США с информацией о работающих гражданах)

Age	Workcl ass	Educati on	...	Hours- per- week	Income
39	State-gov	Bachelors	...	40	<= \$50K
50	Self-emp-inc	Bachelors	...	13	<= \$50K
38	Private	HS-grad	...	40	<= \$50K
		...			...
52	Self-emp-inc	HS-grad	...	40	> \$50K

N объектов

i -ый объект j -ый признак значение j -го признака у i -ый объекта

P признаков

* Kohavi, R. Census Income. UCI Machine Learning Repository, 1996. [URL](#)

Виды признаков объектов

- Входные признаки (input features/attributes)** – атрибуты объектов для предсказания целевых переменных

– для объекта $z^{(i)}$:

– для всей выборки Z :

$$x^{(i)} = \begin{bmatrix} x_1^{(i)} \\ x_2^{(i)} \\ \vdots \\ x_d^{(i)} \end{bmatrix} = [x_1^{(i)}, x_2^{(i)}, \dots, x_d^{(i)}]^T; \quad X = [x^{(1)}, x^{(2)}, \dots, x^{(N)}] = \begin{bmatrix} x_1^{(1)} & x_1^{(2)} & \dots & x_1^{(N)} \\ x_2^{(1)} & x_2^{(2)} & \dots & x_2^{(N)} \\ \vdots & \vdots & \ddots & \vdots \\ x_d^{(1)} & x_d^{(2)} & \dots & x_d^{(N)} \end{bmatrix},$$

где d – количество входных признаков

- Целевые переменные (target variables) или метки (labels)** – атрибуты, которые предсказываются для каждого нового объекта выборки:

– для объекта $z^{(i)}$:

– для всей выборки Z :

$$y^{(i)} = \begin{bmatrix} y_1^{(i)} \\ y_2^{(i)} \\ \vdots \\ y_{d_o}^{(i)} \end{bmatrix} = [y_1^{(i)}, y_2^{(i)}, \dots, y_{d_o}^{(i)}]^T; \quad Y = [y^{(1)}, y^{(2)}, \dots, y^{(N)}] = \begin{bmatrix} y_1^{(1)} & y_1^{(2)} & \dots & y_1^{(N)} \\ y_2^{(1)} & y_2^{(2)} & \dots & y_2^{(N)} \\ \vdots & \vdots & \ddots & \vdots \\ y_{d_o}^{(1)} & y_{d_o}^{(2)} & \dots & y_{d_o}^{(N)} \end{bmatrix},$$

где d_o – количество целевых переменных

Набор данных Census Income

Age	Workclass	Education	...	Hours-per-week	Income
39	State-gov	Bachelors	...	40	<= \$50K
50	Self-emp-inc	Bachelors	...	13	<= \$50K
38	Private	HS-grad	...	40	<= \$50K
...					...
52	Self-emp-inc	HS-grad	...	40	> \$50K

Входные
признаки X

Целевая
переменная Y

Операция транспонирования: $A_{i,j}^T = A_{j,i}$

T – символ транспонирования

Типы признаков

Тип	Область допустимых значений	Примеры
Бинарный	Два значения: 0 или 1, «да» или «нет» $D_j \in \{0, 1\}$ или $D_j \in \{\text{True}, \text{False}\}$	• наличие или отсутствие породы на территории района • пол
Числовой	Множество вещественных чисел $D_j = \mathbb{R}$	• атм. давление • прибыль • скорость
Категориальный	Конечное неупорядоченное множество категорий $D_j = \{c_1, \dots, c_m\}$	• цвет • страна проживания • бренд автомобиля
Порядковый	Конечное <i>упорядоченное</i> множество категорий $D_j = \{c_1, \dots, c_m\}$	• уровень образования • курс обучения • рейтинги

Набор данных Census Income					
Age	Workclass	Education	...	Hours-per-week	Income
39	State-gov	Bachelors	...	40	<= \$50K
50	Self-emp-inc	Bachelors	...	13	<= \$50K
38	Private	HS-grad	...	40	<= \$50K
...					...
52	Self-emp-inc	HS-grad	...	40	> \$50K

- $Age \in \mathbb{R}$
- $Workclass \in \{\text{Private}, \dots, \text{Without-pay}\}$ (7 категорий)
- $Education \in \{\text{HS-grad}, \dots, \text{5th-6th}\}$ (16 категорий)
- ...
- $Hours-per-week \in \mathbb{R}$
- $Income \in \{\leq 50K, > 50K\}$ (2 категории)

Модель

- **Модель (model) A** – параметрическое семейство функций:

$$A = \{g(x, \theta) \mid \theta \in \Theta\},$$

где $g: X \times \Theta \rightarrow Y$ – фиксированная функция, X – множество признаков, описывающих объекты, Y – конечное множество меток, Θ – множество допустимых значений параметров.

- **Пример.**

Линейная модель с вектором параметров $\theta = (\theta_1, \theta_2, \dots, \theta_k) \in \mathbb{R}^k$:

- регрессия

$$g(x, \theta) = \theta_0 + \theta_1 x_1 + \dots + \theta_k x_k, Y = \mathbb{R}$$

- классификация

$$g(x, \theta) = \text{sign}(\theta_0 + \theta_1 x_1 + \dots + \theta_k x_k), Y = \{-1, 1\}$$



Параметры модели

- **Гиперпараметры (hyperparameters)** – параметры, значения которых задаются до начала обучения модели аналитиком и не изменяются в процессе обучения. У модели может не быть гиперпараметров.
- **Обучаемые параметры (parameters)** – параметры, которые изменяются и оптимизируются в процессе обучения модели и итоговые значения этих параметров являются результатом обучения модели.

Пример.

Модель линейной регрессии $g(x, \theta) = \theta_0 + \theta_1 x_1 + \dots + \theta_k x_k = \theta_0 + \sum_{i=1}^k \theta_i x_i = \theta_0 + x^T \theta$:

- гиперпараметры модели: число слагаемых в функции $g(x, \theta)$
- обучаемые параметры: веса модели, настраиваемые в процессе обучения $\theta = (\theta_1, \theta_2, \dots, \theta_k)$

Метод обучения

- Этап обучения (train):

Метод обучения (learning algorithm) $\mu: (X_{train} \times Y_{train}) \rightarrow A$

по выборке $(X_{train}, Y_{train}) = \left(x_{train}^{(i)}, y_{train}^i \right)_{i=1}^{\ell_{train}}$ строит алгоритм $a = \mu((X_{train}, Y_{train}))$:

$$\begin{pmatrix} x_{train,1}^{(1)} & \cdots & x_{train,1}^{(\ell_{train})} \\ \vdots & \ddots & \vdots \\ x_{train,d}^{(1)} & \cdots & x_{train,d}^{(\ell_{train})} \end{pmatrix} \xrightarrow{Y_{train}} \begin{pmatrix} y_{train,1}^{(1)} \\ \vdots \\ y_{train,d}^{(1)} \end{pmatrix} \xrightarrow{\mu} a$$

- Этап тестирования (test):

Алгоритм a для новых объектов $x_{test}^{(i)}$ из тестовой выборки X_{test} выдает ответы $a(x_{test}^{(i)}) = \widehat{y^{(i)}}$:

$$\begin{pmatrix} x_{test,1}^{(1)} & \cdots & x_{test,1}^{(\ell_{test})} \\ \vdots & \ddots & \vdots \\ x_{test,d}^{(1)} & \cdots & x_{test,d}^{(\ell_{test})} \end{pmatrix} \xrightarrow{a} \begin{pmatrix} \widehat{y^{(1)}} \\ \vdots \\ \widehat{y^{(\ell_{test})}} \end{pmatrix}$$

1. Обучающая выборка (training set) – набор данных, который используется для разработки и обучения модели:

где ℓ_{train} – размер обучающей выборки.

2. Валидационная (проверочная) выборка (validation set) – набор данных, который используется для подбора оптимального набора гиперпараметров модели в процессе ее разработки:

где ℓ_{val} – размер валидационной выборки.

3. Тестовая выборка (test set) – набор данных, который позволяет оценить качество обученной модели:

где ℓ_{test} – размер тестовой выборки.

**Обучающая
выборка
50–80 %**

Валидационная выборка 10–25 %

**Тестовая
выборка
10–25 %**

Набор данных Census Income*

Age	Workclass	Education	Occupation	...	HOURS-per-week	Income
39	State-gov	Bachelors	Adm-clerical	...	40	<= \$50K
50	Self-emp-not-inc	Bachelors	Exec-managerial	...	13	<= \$50K
38	Private	HS-grad	Handlers-cleaners	...	40	<= \$50K
...						
52	Self-emp-inc	HS-grad	Exec-managerial	...	40	> \$50K
52	Self-emp-inc	HS-grad	Exec-managerial	...	40	> \$50K
...						
52	Self-emp-inc	HS-grad	Exec-managerial	...	40	> \$50K

Разделение должно быть случайным и выполнять до обучения модели

Оценка точности алгоритма

- **Функция потерь (loss function) $L(a, x)$** – неотрицательная функция, которая характеризует величину ошибки алгоритма $a \in A$ на объекте $x \in X$.
- Функция ошибки выбирается исходя из решаемой задачи:
 - для задачи регрессии: $L(a, x) = |a(x) - y(x)|$, $L(a, x) = (a(x) - y(x))^2$
 - для задачи классификации: $L(a, x) = [a(x) \neq y(x)]$
 - для задачи кластеризации: $L(a, x) = \sum_{i=1}^n \min_c \|x_i - a_c\|^2$
- **Функционал ошибки $\mathcal{L}(a, X)$** – мера качества работы алгоритма $a \in A$ на всей выборке X :

$$\mathcal{L}(a, X) = \frac{1}{n} \sum_{i=1}^n L(a, x^{(i)}).$$

**Чем *меньше* значение функционала ошибки,
тем *лучше* модель справляется с обучением и тем *выше* ее точность**

Обучение модели

- Обучение модели машинного обучения сводится к решению **задачи оптимизации функционала ошибки**:


Необходимо найти такие значения параметров, при которых функционал ошибки достигнет своего минимума:

$$\mathcal{L}(a, X) \rightarrow \min_{a \in \mathcal{A}} \quad \text{или} \quad a(x) = \arg \min_{a \in \mathcal{A}} \mathcal{L}(a, X)$$

Содержание

- Понятие машинного обучения
- Основные определения и обозначения
- **Этапы решения задачи машинного обучения**
- Типы машинного обучения
 - основные задачи машинного обучения
 - примеры прикладных задач


Этапы решения задачи машинного обучения



Этапы решения задачи машинного обучения



Этапы решения задачи машинного обучения



Содержание


- Понятие машинного обучения
- Основные определения и обозначения
- Этапы решения задачи машинного обучения
- **Типы машинного обучения**
 - **основные задачи машинного обучения**
 - **примеры прикладных задач**

Типы машинного обучения

- обучение с учителем (supervised learning)
- обучение без учителя (unsupervised learning)
- частичное обучение (semi-supervised learning)
- обучение с подкреплением (reinforcement learning)

Обучение с учителем


- **Обучение с учителем (supervised learning)** – это процесс обучения модели на наборе *размеченных* данных, когда для каждого объекта имеется метка
- **Дано:** обучающая выборка (X_{train}, Y_{train}) из N объектов
Найти: функцию $g: X \rightarrow Y$, которая аппроксимировала бы неизвестную целевую зависимость как на элементах обучающей выборки (X_{train}, Y_{train}) , так и на всем множестве (X, Y)
- **Примеры задач:**
 - регрессия
 - классификация



Задачи обучения с учителем


Регрессия

– задача машинного обучения, которая прогнозирует числовое значение на основе признаков входных данных



Классификация

– задача машинного обучения, которая распределяет объекты, имеющие одинаковую структуру, по заранее известным группам (классам) в зависимости от схожести атрибутов объектов



Области применения:


- транспорт: предсказание продолжительности поездки на каршеринге
- маркетинг: спрос на товар в конкретный день
- метеорология: прогноз погоды на основе данных с метеостанций и спутников
- ...

Области применения:

- финансы: кредитный скоринг
- транспорт: распознавание дорожных знаков, разметки и участников движения
- медицина: диагностика заболеваний
- металлургия: обнаружение дефектов на прокате
- с/х: мониторинг состояния растений
- ...

Обучение без учителя


- **Обучение без учителя (unsupervised learning)** – это процесс обучения модели на неразмеченных данных, когда данные не содержат метки, и модель должна найти закономерности в данных без контроля со стороны пользователя
- **Примеры задач:**
 - кластеризация
 - понижение размерности данных
 - поиск ассоциативных правил



Задачи обучения без учителя


Кластеризация

— задача машинного обучения, которая распределяет множество объектов одинаковой структуры по заранее неизвестным группам (кластерам) в зависимости от схожести свойств объектов



Понижение размерности данных

— задача машинного обучения, которая уменьшает число признаков набора данных



Области применения:

- маркетинг: разделение потребителей на группы с общими потребностями
- рекомендательные системы: предложение пользователю похожих товаров или услуг на основе его предыдущих предпочтений

Поиск ассоциативных правил

— задача машинного обучения, которая находит в данных часто повторяющиеся закономерности

Области применения:

- маркетинг:
анализ рыночной корзины

