


Машинное обучение: как найти то, что скрыто в данных?

Классификация



*Классификация – нить Ариадны
в лабиринте природы.*

Жорж Санд

[Cipolla C.M. The basic laws of human stupidity](#). Bologna: il Mulino, 2011

Содержание

- Постановка задачи
- Деревья решений
- Оценка качества классификации

Содержание

- **Постановка задачи**
- Деревья решений
- Оценка качества классификации


Задача классификации

- Задача машинного обучения с учителем, которая заключается в распределении объектов одинаковой структуры по заранее известным группам (*классам*) в зависимости от похожести свойств объектов
- Основные задачи классификации:
 - **Предсказание:** назначить корректный класс объекту, который предварительно не был рассмотрен
 - **Описание:** указать способ, с помощью которого можно отличать объекты различных классов

Задача регрессии vs Задача классификации


Регрессия

- восстановление зависимости между признаками и числовой целевой переменной
- предсказывание числа для объекта




Классификация

- построение границ принятия решений между классами
- отнесение объекта к одному из классов



Выборки




Данные: таблицы



#	Пол	Возраст	Кол-во звонков	Длит. звонков	Интернет трафик	Тариф	Сумма платежа	...	УЙДЕТ
1	М	24	103	146	1.1	А	50	...	НЕТ
2	М	28	217	307	2.7	А	60	...	ДА
3	Ф	29	308	965	3.5	В	30	...	НЕТ
4	М	33	92	180	3.1	Б	100	...	НЕТ
5	М	53	78	28.34	1.2	В	80	...	ДА







- Данные клиентов мобильного оператора для анализа оттока



#	Пол	Класс	% верных заданий	Кол-во «✓»	Кол-во «?»	Кол-во исправл.	...	ОЦЕНКА
1	Ф	8А	65	0	4	2	...	4-
2	Ф	8А	70	4	0	4	...	3
3	Ф	8А	85	0	0	4	...	4
4	М	8Б	55	0	0	1	...	3
5	М	8Б	40	1	2	0	...	2
6	М	8А	65	0	3	4	...	4-
							...	

- Анонимные данные об оценках учеников за контрольную работу в школе для предсказания успеваемости студентов

Данные: изображения

Снимок	ДЕФЕКТ	Снимок	ДЕФЕКТ
	Раковина		Пятна
	Неметалл. включения		Окалина
	Царапина		Раковина
	Трещина		Пятна

- Снимки поверхности стальных горячекатаных полос, получаемые в процессе прокатки на металлургическом стане, для определения дефектов



Данные: тексты

Ресторан	Отзыв	ОЦЕНКА
Beyond Flavours	The ambience was good, food was quite good . had Saturday lunch , which was cost effective .Good place for a sate brunch. One can also chill with friends and or parents.Waiter Soumen Das was really courteous and helpful.	5
Beyond Flavours	Ambience is too good for a pleasant evening. Service is very prompt. Food is good. Over all a good experience. Soumen Das - kudos to the service	5
Beyond Flavours	A must try.. great food great ambience. Thnx for the service by Pradeep and Subroto. My personal recommendation is Penne Alfredo Pasta:) Also the music in the background is amazing.	5
...	...	...


- Отзывы клиентов от посещения ими различных ресторанов для определение эмоциональной окраски



Типы задач классификации


Бинарная классификация (binary classification)

определение объекта
к одному из *двух* классов




Многоклассовая классификация (multiclass classification)

определение объекта к одному
из *нескольких* классов



Классификация по многим меткам (multilabel classification)

определение объекта
одновременно
к *нескольким* классам






Практическое применение

- **медицина:**
 - определение вида заболевания по результатам обследования пациента и имеющимся симптомам
- **металлургия:**
 - распознавание дефектов на листовом металлопрокате
 - прогнозирование свойств материалов по заданным параметрам химического состава
- **банковская сфера:**
 - оценивание кредитоспособности и надежности заемщиков по их кредитной истории
- **лингвистика:**
 - анализ тональности текста (например, отзывов о товаре и услугах, комментариев на сайтах, ответов на вопросы и публикаций)
- **маркетинг:**
 - прогнозирование оттока клиентов
- **сфера безопасности:**
 - обнаружение мошеннических операций и предотвращение кибератак

Процесс классификации: обучение (индукция)

Обучающая выборка


ФИО	Доход	Возраст	...	Дать кредит
Бонд Дж.	средний	пожилой		нет
Бэннер Б.	высокий	пожилой		да
Кент К.	низкий	пожилой		нет
Паркер П.	низкий	молодой		нет
Скайуокер Э.	низкий	молодой		нет
Сойер Т.	высокий	средний		да
Соло Х.	низкий	средний		нет
Старк Т.	высокий	средний		да



Модель классификации

Процесс классификации: оценка качества

Модель классификации



Тестовая выборка

ФИО	Доход	Возраст	...	Дать кредит
Вейдер Д.	низкий	средний		нет
Винду М.	низкий	молодой		нет
Дюррон К.	низкий	молодой		нет
Органа Л.	высокий	средний		да
Хатт Дж.	низкий	пожилой		да


Результаты модели

Дать кредит
нет
нет
да
нет
нет

Точность
60%

Процесс классификации: применение (дедукция)

Модель классификации



Неразмеченные данные

ФИО	Доход	Возраст	...
Бендер О.С.	низкий	пожилой	
Иванов И.И.	высокий	молодой	
Михельсон К.К.	высокий	средний	
Петров П.П.	низкий	средний	
...			

Результаты модели


Дать кредит
нет
да
да
нет
...

Содержание


- Постановка задачи
- **Деревья решений**
- Оценка качества классификации

Деревья решений

- **Дерево решений (decision tree)** – модель классификации в виде дерева, которое имеет
 - корневой узел и внутренние узлы: проверка условия на атрибут объекта
 - узлы-листья: метки классов
 - ребра: переходы по результату проверки



Деревья решений



- Для применения не требуется компьютер
- Сферы применения: банковское дело, страхование, торговля, медицина, контроль качества продукции

Построение дерева решений (алгоритм Ханта)

NULL


ФИО	Доход	Возраст	...	Дать кредит
Бонд Дж.	средний	пожилой		нет
Бэннер Б.	высокий	пожилой		да
Кент К.	низкий	пожилой		нет
Паркер П.	низкий	молодой		нет
Скайуокер Э.	низкий	молодой		нет
Сойер Т.	высокий	средний		да
Соло Х.	низкий	средний		нет
Старк Т.	высокий	средний		да



Earl Hunt
1933-2016

- Если все объекты из одного класса, то создать лист с меткой этого класса, иначе выбрать атрибут для разбиения


Построение дерева решений (алгоритм Ханта)



- Разбить выборку в соответствии со значениями выбранного атрибута
- Рекурсивно построить поддеревья


Выбор атрибута разбиения

- Какой атрибут выбрать для разбиения?




Выбор атрибута разбиения

- Жадный подход*: выбрать атрибут, разбивающий выборку на подмножества с минимальной долей «примесей» (объектов иного класса)



Критерий выбора атрибута – прирост информации



Оценка доли примесей с помощью энтропии

$$Entropy = - \sum_{i=1}^n p_i \cdot \log_2 p_i$$


n — количество классов

p_i — вероятность объектов i -го класса в выборке узла

to be, or not to be, that is the question аааааааааааааааа...а

i	Sym	num	p	-p*log2(p)
1	space	9	0.22	0.48
2	comma	2	0.05	0.21
3	a	1	0.02	0.13
4	b	2	0.05	0.21
5	e	4	0.10	0.33
6	h	2	0.05	0.21
7	i	2	0.05	0.21
8	n	2	0.05	0.21
9	o	5	0.12	0.37
10	q	1	0.02	0.13
11	r	1	0.02	0.13
12	s	2	0.05	0.21
13	t	7	0.17	0.44
14	u	1	0.02	0.13
		41		3.41

i	Sym	num	p	-p*log2(p)
1	a	41	1.00	0.00
2				
3				
4				
5				
6				
7				
8				
9				
10				
11				
12				
13				
14				
		41		0.00



Клод Шеннон
1916-2001

Алгоритм ID3 (Iterative Dichotomiser 3)

- $Entropy = - \sum_{i=1}^n p_i \cdot \log_2 p_i$
- $\max Entropy = \log_2 n$, когда объекты равномерно распределены по классам (наименее желательная ситуация)
- $\min Entropy = 0$, когда объекты принадлежат одному классу (наиболее желательная ситуация)



John Ross
Quinlan

Вычисление энтропии узла дерева решений

- $Entropy = -\sum_{i=1}^n p_i \cdot \log_2 p_i$

$0 \cdot \log_2 0$ считается 0

- | |
|---|
| 0 |
| 6 |

 $Entropy = -\frac{0}{6} \cdot \log_2 0 - \frac{6}{6} \cdot \log_2 \frac{1}{1} = 0$
- | |
|---|
| 1 |
| 5 |

 $Entropy = -\frac{1}{6} \cdot \log_2 \frac{1}{6} - \frac{5}{6} \cdot \log_2 \frac{5}{6} = 0.65$
- | |
|---|
| 2 |
| 4 |

 $Entropy = -\frac{2}{6} \cdot \log_2 \frac{2}{6} - \frac{4}{6} \cdot \log_2 \frac{4}{6} = 0.92$

Вычисление прироста информации после разбиения узла по атрибуту

- $Gain(A) = Entropy(node) - Info(A)$,

$$Entropy(node) = - \sum_{i=1}^n p_i \cdot \log_2 p_i ,$$

$$Info(A) = \sum_{i=1}^k \frac{n_i}{n} Entropy(child_i) ,$$

где A – атрибут разбиения с k различных значений,

n – количество объектов в выборке разбиваемого узла-родителя $node$,


n_i – количество объектов в выборке узла-потомка $child_i$

- Для разбиения выбирается атрибут


$$A_{split} = \arg \max_i Gain(A_i) = \arg \min_i Info(A_i)$$

Пример построения дерева решений по ID3

#	Attribute			Shape
	Color	Outline	Dot	
1	green	dashed	no	triange
2	green	dashed	yes	triange
3	yellow	dashed	no	square
4	red	dashed	no	square
5	red	solid	no	square
6	red	solid	yes	triange
7	green	solid	no	square
8	green	dashed	no	triange
9	yellow	solid	yes	square
10	red	solid	no	square
11	green	solid	yes	square
12	yellow	dashed	yes	square
13	yellow	solid	no	square
14	red	dashed	yes	triange




Пример: вычисление энтропии узла-родителя




- ***Entropy*** = $-\frac{9}{14} \cdot \log_2 \frac{9}{14} - \frac{5}{14} \cdot \log_2 \frac{5}{14} = \mathbf{0.94}$

Пример: вычисление энтропии узлов-потомков




- $Entropy(yellow) = 0$
- $Entropy(green) = -\frac{2}{5} \cdot \log_2 \frac{2}{5} - \frac{3}{5} \cdot \log_2 \frac{3}{5} = \mathbf{0.971}$
- $Entropy(red) = -\frac{3}{5} \cdot \log_2 \frac{3}{5} - \frac{2}{5} \cdot \log_2 \frac{2}{5} = \mathbf{0.971}$

Пример: вычисление прироста информации




- $Info(Color) = \frac{4}{14} \cdot 0 + \frac{5}{14} \cdot 0.971 + \frac{5}{14} \cdot 0.971 = \mathbf{0.694}$
- $Gain(Color) = 0.94 - 0.694 = \mathbf{0.246}$

Пример: выбор атрибута разбиения




- **$Gain(Color) = 0.246$**
- $Gain(Outline) = 0.151$
- $Gain(Dot) = 0.048$

Пример: выбор атрибута разбиения





- $Gain(Outline) = 0.971$
- $Gain(Dot) = 0.971 - 0.951 = 0.02$

Пример: выбор атрибута разбиения



Пример: итоговое дерево решений



Содержание

- Постановка задачи
- Деревья решений
- **Оценка качества классификации**

Матрица ошибок (Confusion matrix)

Реальность


C (Positive)

$\neg C$ (Negative)

П
р
о
г
н
о
з

C
(Positive)

$\neg C$
(Negative)

<i>True Positives (TP)</i> 	<i>False Positives (FP)</i> 
<i>False Negatives (FN)</i> 	<i>True Negatives (TN)</i> 

- C – cat
- $\neg C$ – dog

Матрица ошибок (Confusion matrix)

Прогноз \ Реальн.	C	$\neg C$
C	<i>True Positives (TP)</i>	<i>False Positives (FP)</i>
$\neg C$	<i>False Negatives (FN)</i>	<i>True Negatives (TN)</i>

- TP – верно распознанные объекты класса C
- TN – верно распознанные объекты класса $\neg C$
- FN – объекты класса C , неверно распознанные как объекты класса $\neg C$
- FP – объекты класса $\neg C$, неверно распознанные как объекты класса C
- $P = TP + FN$ – объекты класса C
- $N = FP + TN$ – объекты класса $\neg C$

Accuracy (Аккуратность) и *Error* (Доля ошибок)

- $Accuracy = \frac{TP+TN}{P+N} = \frac{TP+TN}{TP+FN+FP+TN}$
- $Error = 1 - Accuracy = \frac{FP+FN}{P+N} = \frac{FP+FN}{TP+FN+FP+TN}$
- Наиболее простой способ оценки качества:
доля верных/неверных ответов

$P \backslash C$	C	$\neg C$
C	TP	FP
$\neg C$	FN	TN

Accuracy и *Error* не всегда хороши


П\Р	Рак = да	Рак = нет
Рак = да	$TP = 1$	$FP = 9$
Рак = нет	$FN = 2$	$TN = 988$
Всего	$P = 3$	$N = 997$

- $Accuracy = \frac{1+988}{1+2+9+988} = 98.9\%, Error = 1.1\%$
- Классификатор идеально распознает отсутствие рака и плохо распознает рак
- При дисбалансе классов в обучающей выборке **нужны отдельные меры качества распознавания объектов из классов C и $\neg C$**

Precision (точность), *Recall* (полнота)

- Точность* показывает долю объектов, верно распознанных моделью как объекты класса C , от всех объектов, распознанных моделью как объекты класса C


$$Precision = \frac{TP}{TP+FP}$$



$\Pi \backslash P$	C	$\neg C$
C	TP	FP
$\neg C$	FN	TN

- Полнота* показывает долю объектов, верно распознанных моделью как объекты класса C , от всех объектов класса C

$$Recall = \frac{TP}{TP+FN}$$



$\Pi \backslash P$	C	$\neg C$
C	TP	FP
$\neg C$	FN	TN

Пример

Прогноз\Реальн.	Рак = Да	Рак = Нет
Рак = Да	90 <i>TP</i>	140 <i>FP</i>
Рак = Нет	210 <i>FN</i>	9560 <i>TN</i>
Всего	300 <i>P</i>	9700 <i>N</i>

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

- $Accuracy = \frac{90+9560}{300+9700} = 96.5\%$
- $Precision = \frac{90}{90+140} = 39.13\%$
- $Error = 3.5\%$
- $Recall = \frac{90}{90+210} = 30\%$

Мера F

- Мера F (F_1 или F -score) – среднее гармоническое точности и полноты

$$F = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}} = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

- Среднее гармоническое двух чисел ближе минимальному из них, чем среднее арифметическое и геометрическое

a	b	$\frac{a+b}{2}$	$\sqrt[2]{ab}$	$\frac{2}{\frac{1}{a} + \frac{1}{b}}$
1	5	3	2.236	1.667

Пример

Прогноз\Реальн.	Рак = Да	Рак = Нет
Рак = Да	90 <i>TP</i>	140 <i>FP</i>
Рак = Нет	210 <i>FN</i>	9560 <i>TN</i>
Всего	300 <i>P</i>	9700 <i>N</i>

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall}$$

- $Accuracy = \frac{90+9560}{300+9700} = 96.5\%, Error = 3.5\%$


- $Precision = \frac{90}{90+140} = 39.13\%, Recall = \frac{90}{90+210} = 30\%$

- $F = \frac{2 \cdot 0.3913 \cdot 0.3}{0.3913 + 0.3} = 0.34$

Пример: анализ удовлетворенности клиентов

- **Задача:** определение степени удовлетворенности пассажиров услугами авиакомпаний
- **Данные:** результаты опроса пассажиров авиакомпаний об их удовлетворенности обслуживания клиентов

№	Пол	Возраст	Класс	Задержка вылета, мин	...	Удовл-ть регистрацией на рейс	Итоговая удовл-ть
1	М	13	Эко +	25	...	4	Не удовлетворен
2	М	25	Бизнес	1	...	1	Не удовлетворен
3	Ж	26	Бизнес	0	...	4	Удовлетворен
4	Ж	25	Бизнес	11	...	1	Не удовлетворен
5	М	61	Бизнес	0	...	3	Удовлетворен
6	Ж	26	Эко	0	...	4	Не удовлетворен
...							...



Пример: поиск полезных ископаемых

- **Задача:** определение степени удовлетворенности пассажиров услугами авиакомпаний
- **Данные:** результаты опроса пассажиров авиакомпаний об их удовлетворенности обслуживания



№	FeSO ₄ • 7H ₂ O		NH ₄ H ₂ PO ₄		(Na,Ca) (Si,Al) ₄ O ₈		SiO ₂ •nH ₂ O		LiAl Si ₄ O ₁₀		...	Ископаемое
	Наличие	Плотность	Наличие	Плотность	Наличие	Плотность	Наличие	Плотность	Наличие	Плотность		
1	Да	3.40	Нет	-	Да	7.80	Нет	-	Да	23.92	...	Железо
2	Нет	-	Да	7.22	Да	2.97	Да	5.97	Да	16.54	...	Медь
3	Да	4.67	Да	5.45	Да	5.43	Да	8.95	Да	28.49	...	Серебро
4	Нет	-	Да	3.12	Нет	-	Да	9.12	Нет	-	...	Цинк
5	Да	1.02	Нет	-	Нет	-	Да	1.23	Да	2.12	...	НЕТ
6	Да	0.75	Нет	-	Нет	-	Да	3.10	Да	2.99	...	НЕТ
...												...

