


# Машинное обучение: как найти то, что скрыто в данных?

## Кластеризация



*Группа людей, действуя  
совместно, может свершить  
такое, о чем поодиночке они не  
могли бы и мечтать.*

*Франклин Рузвельт*

# Содержание


- Постановка задачи
- Разделительная кластеризация
- Оценка качества кластеризации

# Содержание

- **Постановка задачи**
- Разделительная кластеризация
- Оценка качества кластеризации

# Задача кластеризации

- Задача машинного обучения без учителя, заключающаяся в разбиении множества объектов на заранее неизвестные группы (*кластеры*) таким образом, чтобы объекты внутри одного кластера были существенно похожи, а объекты из разных кластеров существенно различны







# Практическое применение

- **Понимание данных**
  - биология: иерархии живых организмов
  - землепользование: нахождение в базе наблюдений Земли сходных территорий
  - маркетинг: таргетирование клиентов
  - городское планирование: группы похожих зданий
  - изучение землетрясений: кластеризация эпицентров
- **Предобработка данных**
  - редукция (сжатие) данных: замена группы объектов их центроидом
  - удаление выбросов (новизны): нахождение объектов, наиболее удаленных от всех кластеров
  - восстановление пропущенных данных: использование координат центроидов
  - нахождение ближайших соседей: поиск среди объектов того же кластера







# Неоднозначность кластеризации: число групп



Сколько кластеров?

6



2

4

# Неоднозначность кластеризации

- Выбор функции расстояния (или меры схожести)
- Выбор критерия качества кластеризации
- Размерность данных
- Типы атрибутов
- Зависимости между атрибутами
- Распределение данных
- Наличие шумов и выбросов в данных



# Подходы кластеризации

- *Разделительная*: разделяет объекты на заданное число непересекающихся кластеров, минимизируя расстояние внутри кластера и максимизируя расстояние между кластерами ( $k$ -means, CLARANS)
- *Плотностная*: группирует объекты, которые находятся в областях с высокой плотностью и отделяют их от областей с низкой плотностью (DBSCAN)
- *Иерархическая*: создается иерархия (дерево) вложенных разбиений (кластеров) исходного множества объектов (агломеративный, дивизивный)
- *Основанная на сетке*: разбивается пространство на ячейки сетки и анализируется плотность данных в каждой ячейке (STING)
- *Графовая*: используется графовое представление данных, которое разбивается на подграфы, соответствующие кластерам (спектральная кластеризация)
- *Основанная на подпространствах*: выполняется поиск кластеров в подпространствах признаков, а не во всем пространстве (CLIQUE)



# Содержание

- Постановка задачи
- **Разделительная кластеризация**
- Оценка качества кластеризации

# Разделительный алгоритм *k*-means (*k*-средних)


- Количество кластеров  $k$  – параметр алгоритма
- Кластер ассоциируется с его центроидом (центральной точкой)
- Объект принадлежит кластеру с ближайшим к нему центроидом

---


- 1: Select  $K$  points as the initial centroids.
- 2: **repeat**
- 3:   Form  $K$  clusters by assigning all points to the closest centroid.
- 4:   Recompute the centroid of each cluster.
- 5: **until** The centroids don't change

---

# Пример работы $k$ -means



# Пример работы $k$ -means



# Детали алгоритма *k-means*

- Начальные центроиды берутся случайным образом.  
Результат кластеризации не детерминирован
- Центроид – обычно точка с усредненными координатами точек кластера
- Алгоритм сходится в начальных итерациях для общепринятых метрик
  - часто изменяется условие останова: у малого числа точек изменен кластер
  - может давать локальный минимум вместо глобального



# Мера для выявления кластеров в *k*-means

- Сумма квадратов ошибок, Sum of Squared Errors

$$SSE = \sum_{i=1}^k \sum_{x \in C_i} dist^2(m_i, x)$$

- $x$  — точка кластера  $C_i$  ( $1 < i < k$ )
  - $m_i$  — репрезентативная точка (центр) кластера
  - для точки ошибкой является расстояние до ближайшего кластера
- Из двух вариантов кластеризации выбирается имеющий меньшую суммарную ошибку
    - Увеличение  $k$  уменьшает ошибку. Хороший вариант кластеризации с меньшим  $k$  может иметь меньшее  $SSE$ , чем плохой вариант с большим  $k$


# За и против *k*-means

- Достоинства
  - невысокая сложность:  $O(n \cdot k \cdot d \cdot i)$ ,  
где  $n$  – мощность множества объектов,  $d$  – размерность объекта,  
 $i$  – число итераций (обычно  $i \ll n$ )
  - сходится в начальных итерациях для общепринятых метрик
- Недостатки
  - необходимость в задании параметра  $k$
  - недетерминированный результат
  - неприменимость к категориальным данным  
(для них нужно использовать *k*-modes)
  - неприменимость для кластеров невыпуклой формы
  - чувствительность к размеру, плотности, шумам и выбросам в данных




# Различные варианты кластеризации $k$ -means


Оптимальная  
кластеризация




Кластеризуемое  
множество




Суб-оптимальная  
кластеризация



# Влияние размеров кластеров




**Кластеризуемое  
множество**




**3-means**

# Влияние плотности кластеров




**Кластеризуемое  
множество**




**3-means**

# Влияние формы кластеров




**Кластеризуемое  
множество**




**2-means**

# Увеличение количества кластеров



**Кластеризуемое множество**




**10-means**


- Может помочь, но требует дальнейшего объединения некоторых полученных кластеров (например, с помощью иерархической кластеризации)



# Увеличение количества кластеров



Кластеризуемое множество




10-means


- Может помочь, но требует дальнейшего объединения некоторых полученных кластеров (например, с помощью иерархической кластеризации)



# Увеличение количества кластеров




**Кластеризуемое множество**




**10-means**

- Может помочь, но требует дальнейшего объединения некоторых полученных кластеров (например, с помощью иерархической кластеризации)


# Влияние шумов и выбросов




В данных  
нет шума  
 $S=0.88$



В 3% данных  
есть шум  
 $S=0.62$




В 5% данных  
есть шум  
 $S=0.39$




В 10% данных  
есть шум  
 $S=-0.05$




# Влияние начального выбора центроидов (1)




# Влияние начального выбора центроидов (1)



# Влияние начального выбора центроидов (2)



# Влияние начального выбора центроидов (2)




# Подбор начальных центроидов

- Многократно запустить  $k$ -means, выбрать результат с минимальным значением  $SSE$ 
  - результат не обязан быть лучшим из возможных
- Выполнить иерархическую кластеризацию случайного подмножества исходных точек для  $k$  кластеров и взять центроиды этих кластеров
  - работает для небольших подмножеств и значений  $k$
- Взять центроид всех точек, затем  $k - 1$  раз взять точку, наиболее удаленную от всех  $k$  выбранных до этого центроидов
  - в качестве центроида может быть взят выброс
  - высокая трудоемкость
- Применить предыдущий подход для случайного подмножества точек



# ***k*-medoids (PAM, Partitioning Around Medoids)**

- Медоид – репрезентативный объект кластера



- Менее чувствителен к шумам и выбросам, чем *k*-means (медоид – объект кластера, центроид – искусственный объект)

# ***k*-medoids (PAM, Partitioning Around Medoids)**

взять  $k$  случайных объектов в качестве медоидов  $\check{o}_1, \dots, \check{o}_k$

**repeat**

назначить объектам кластер с ближайшим медоидом;

выбрать случайный объект не-медоид  $o$ ;

вычислить цену обмена  $o$  и  $\check{o}$  как разность их  $SSE$

$$E = \sum_{i=1}^k \sum_{p \in c_i} \text{dist}(p, o)^2 - \sum_{i=1}^k \sum_{p \in c_i} \text{dist}(p, \check{o})^2;$$


**if  $E < 0$  then**

обменивать местами объект  $o$  и медоид  $\check{o}$


**until** нет изменений




# Пример работы $k$ -medoids

 $k=2$ 


Выбрать  $k$   
случайных  
объектов в  
качестве  
медоидов




Присвоить  
оставшимся  
объектам  
кластеры по  
ближайшему  
медоиду



Выбрать случайный объект  
не-медоид,  $O_{\text{random}}$



Вычислить  
стоимость  
обмена медоида  
и  $O_{\text{random}}$



**repeat**



Если качество  
улучшилось,  
поменять медоид  
и  $O_{\text{random}}$

**until** нет изменений

# Содержание

- Постановка задачи
- Разделительная кластеризация
- **Оценка качества кластеризации**

# Оптимальное число кластеров: метод локтя



$$SSE(D) = \sum_{i=1}^k \sum_{j=1}^{|C_i|} dist^2(c_i, x_j)$$


$D = \{x_j\}$  – исходное множество,  $c_i$  – центроид кластера  $C_i$

# Кросс-валидация для оптимального числа кластеров

- Разбить исходное множество на  $m$  частей
- Для различных  $k$ 
  - Выполнить кластеризацию  $m - 1$  частей
  - Для  $m$ -й части вычислить  $SSE = \sum dist^2(c, x)$ , где  $x$  – объект этой части,  $c$  – ближайший к нему центроид
  - Повторить кластеризацию и вычисление  $SSE$  для всех частей
  - Вычислить среднее  $SSE$
- Взять значение  $k$ , при котором среднее значение  $SSE$  минимально

# Оценка качества кластеризации через корреляцию


- Матрица расстояний:
  - $(d_{ij}) = dist(x_i, x_j)$
- Матрица идеальной схожести:
  - $(s_{ij}) = \begin{cases} 0, & x_i \in C_p \wedge x_j \in C_q \\ 1, & x_i, x_j \in C_p \end{cases}$
- Вычислить  $corr_{d,s}$ 
  - Высокая корреляция покажет, что объекты одного кластера близки друг к другу





# Визуальная оценка качества кластеризации по матрице расстояний (схожести)


- Упорядочить объекты кластеризованного множества пометкам кластеров и визуализировать матрицу расстояний (схожести)





# Силуэтный коэффициент

- **Сцепление** точки с другими точками того же кластера: среднее расстояние от данной точки до других точек кластера
  - $a(p) = \frac{1}{|C_i|-1} \sum_{q \in C_i \wedge q \neq p} dist(p, q)$
- **Отдаленность** точки от точек других кластеров: минимум среднего расстояния до точек других кластеров
  - $b(p) = \min_{C_j \neq C_i} \frac{1}{|C_j|} \sum_{q \in C_j} dist(p, q)$
- Силуэтный коэффициент
  - для одной точки:  $s(p) = \frac{b(p) - a(p)}{\max\{a(p), b(p)\}}$
  - для множества точек:  $S(D) = \frac{1}{|D|} \sum_{p \in D} s(p)$
- $-1 \leq s, S \leq 1$ 
  - Чем ближе к 1, тем выше качество кластеризации
  - При отрицательном значении качество кластеризации низкое





# Пример: вычисление силуэтного коэффициента

