


Машинное обучение: как найти то, что скрыто в данных?

Регрессия



*Когда средний рост родителей выше среднего, их дети, как правило, ниже их...
Когда средний рост родителей ниже среднего, их дети, как правило, выше их.*

Фрэнсис Гальтон

Содержание

- Постановка задачи, модели регрессии
- Линейная регрессия
 - измерение ошибки в задачах линейной регрессии
 - обучение линейной регрессии
 - метод наименьших квадратов
 - метод градиентного спуска
- Полиномиальная регрессия

Содержание

- **Постановка задачи, модели регрессии**
- Линейная регрессия
 - измерение ошибки в задачах линейной регрессии
 - обучение линейной регрессии
 - метод наименьших квадратов
 - метод градиентного спуска
- Полиномиальная регрессия

Задача регрессии

- **Регрессия (regression)** – это задача машинного обучения с учителем, которая прогнозирует числовое значение целевой переменной на основе входных признаков с помощью уравнения регрессии
- **Уравнение регрессии** – это математическая функция, которая подбирается на основе целевой переменной и входных признаков данных и выражает зависимость между ними
- **Математическая постановка:**

Дано: обучающая выборка $(X_{train}, Y_{train}) = \left\{ \left(x_{train}^{(i)}, y_{train}^{(i)} \right) \right\}_{i=1}^{\ell_{train}}$, где $y_{train}^{(i)} \in \mathbb{R}$.

Найти: функцию вида $f(x, w) \rightarrow \mathbb{R}$,
 где x – вектор входных признаков,
 w – вектор параметров функции.

Набор данных

Входные признаки X	Целевая переменная Y
$\left(x_1^{(1)}, x_2^{(1)}, \dots, x_d^{(1)} \right)$	$y_1^{(1)}$
$\left(x_1^{(2)}, x_2^{(2)}, \dots, x_d^{(2)} \right)$	$y_1^{(2)}$
...	...
$\left(x_1^{(N-1)}, x_2^{(N-1)}, \dots, x_d^{(N-1)} \right)$	$y_1^{(N-1)}$
$\left(x_1^{(N)}, x_2^{(N)}, \dots, x_d^{(N)} \right)$	$y_1^{(N)}$



Регрессионные модели

- линейная регрессия
моделирует линейные зависимости между переменными
- логистическая регрессия
оценивает наличие связи между бинарной целевой переменной и несколькими входными переменными
- полиномиальная регрессия
моделирует сложные, нелинейные зависимости между переменными
- лассо- и гребневая регрессия
моделируют линейные зависимости между переменными с учетом регуляризации
- квантильная регрессия
моделирует взаимосвязь между входными переменными и определенными процентилями целевой переменной
- ...

Практическое применение

- **Метеорология:**
 - прогноз погоды (температура, влажность и давление) на основе данных с метеостанций и спутников
- **Финансы:**
 - предсказание рыночных и экономических показателей
- **Маркетинг:**
 - прогноз спроса на конкретный товар в конкретный день
 - прогноз ожидаемого дохода магазина на следующий месяц
- **Геология:**
 - оценка вероятности землетрясения в конкретную дату
- **Химическое материаловедение:**
 - прогноз свойств получаемого соединений (температура плавления, электропроводность, теплоемкость) по параметрам химических элементов
- **Транспорт:**
 - прогноз расхода топлива по техническим характеристикам автомобиля и режиму езды
 - предсказание продолжительности поездки на каршеринге
- **Кредитный скоринг:**
 - оценка величины кредитного лимита по анкете заемщика

Содержание

- Постановка задачи, модели регрессии
- **Линейная регрессия**
 - измерение ошибки в задачах линейной регрессии
 - обучение линейной регрессии
 - метод наименьших квадратов
 - метод градиентного спуска
- Полиномиальная регрессия

Линейная регрессия

- **Линейная регрессия (linear regression)** – регрессионная модель зависимости целевой переменной от входных признаков данных с линейной функцией зависимости.
- Уравнение линейной регрессии имеет следующий вид:
 - в классической форме:

$$y = \theta_0 + \theta_1 x_1 + \dots + \theta_d x_d = \theta_0 + \sum_{j=1}^d \theta_j x_j,$$

где θ_0 – смещение (bias), $\theta_0 \in \mathbb{R}$;

θ_j – вес j -го признака (weight), $\theta_j \in \mathbb{R}$;

x_j – значение j -го признака, $x_j \in \mathbb{R}$, $1 \leq j \leq d$;



d – количество входных признаков, $d \geq 1$.

- в векторной форме:

$$y = \Theta^T \cdot x = \langle \Theta, x \rangle,$$

где $\Theta = (\theta_0, \theta_1, \dots, \theta_d)^T$ – вектор весов и смещения, $\Theta \in \mathbb{R}^{d+1}$;

$x = (1, x_1, \dots, x_d)^T$ – вектор признаков, $x \in \mathbb{R}^{d+1}$.








Задача линейной регрессии

Обучающая
выборка

Площадь, м ²	Цена, млн.
31	3.5
82	12.5
77	7
56	5.8
52	6.8
65	8.2
90	8.9
36	3.6
142	15.1

Построение
линейной
регрессии



Какая прямая лучше подходит под данные?
Как найти эту прямую?


Обучение линейной регрессии

- Найти оптимально подогнанную прямую линию, максимально близко проходящую через все точки данных

или

- Найти такие параметры модели линейной регрессии (веса и смещение) на основе обучающей выборки, при которых функционал ошибки достигнет своего минимума:

$$\mathcal{L}(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} L(a, x^{(i)}) = \frac{1}{\ell} \sum_{i=1}^{\ell} \varepsilon^{(i)} \rightarrow \min$$



Содержание

- Постановка задачи, модели регрессии
- **Линейная регрессия**
 - **измерение ошибки в задачах линейной регрессии**
 - обучение линейной регрессии
 - метод наименьших квадратов
 - метод градиентного спуска
- Полиномиальная регрессия

Функционал ошибки для линейной регрессии

- **Среднеквадратичное отклонение**
(Mean Squared Error, MSE):

$$\text{MSE}(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a(x^{(i)}) - y^{(i)})^2, \quad \text{MSE}(a, X) \geq 0.$$

- **Корень из среднеквадратичного отклонения**
(Root Mean Squared Error, RMSE):

$$\text{RMSE}(a, X) = \sqrt{\frac{1}{\ell} \sum_{i=1}^{\ell} (a(x^{(i)}) - y^{(i)})^2}, \quad \text{RMSE}(a, X) \geq 0.$$

- **Среднее абсолютное отклонение**
(Mean Absolute Error, MAE):

$$\text{MAE}(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} |a(x^{(i)}) - y^{(i)}|, \quad \text{MAE}(a, X) \geq 0.$$

- Чем **больше** значение MSE, RMSE или MAE, тем **сильнее** модель ошибается.

Свойство	MSE	RMSE	MAE
Интерпретируемость			
Дифференцируемость			
Чувствительность к выбросам, большим ошибкам			

Пример

y	$a(x)$	$(a(x^{(i)}) - y^{(i)})^2$	$ a(x^{(i)}) - y^{(i)} $
5	8	9	3
7	21	196	14
4	5	1	1
2	4	4	2
9	6	9	3

- $\text{MSE}(a, X) = (9 + 196 + 1 + 4 + 9)/5 = 43.8$
- $\text{RMSE}(a, X) = \sqrt{(9 + 196 + 1 + 4 + 9)/5} = 6.6$
- $\text{MAE}(a, X) = (3 + 14 + 1 + 2 + 3)/5 = 4.6$

Содержание

- Постановка задачи, модели регрессии
- **Линейная регрессия**
 - измерение ошибки в задачах линейной регрессии
 - **обучение линейной регрессии**
 - **метод наименьших квадратов**
 - метод градиентного спуска
- Полиномиальная регрессия

Метод наименьших квадратов

- **Метод наименьших квадратов (МНК, Least Squares Method)** – математический метод для оценки параметров моделей, основанный на минимизации суммы квадратов отклонений между фактическими значениями и значениями, оцененными моделью.
- Для линейной регрессии:

$$\mathcal{L}(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a(x^{(i)}) - y^{(i)})^2 \rightarrow \min.$$

Для нахождения весов $(\theta_1, \dots, \theta_d)$ и смещения θ_0 должно выполняться условие минимума функции:

$$\begin{cases} \frac{\partial \mathcal{L}}{\partial \theta_0} = 0 \\ \vdots \\ \frac{\partial \mathcal{L}}{\partial \theta_d} = 0 \end{cases}$$


$\Rightarrow$

Для одномерной линейной регрессии:

$$\theta_1 = \frac{\ell \sum_{i=1}^{\ell} x^{(i)} y^{(i)} - \sum_{i=1}^{\ell} x^{(i)} \sum_{i=1}^{\ell} y^{(i)}}{\ell \sum_{i=1}^{\ell} (x^{(i)})^2 - (\sum_{i=1}^{\ell} x^{(i)})^2}, \quad \theta_0 = \frac{\sum_{i=1}^{\ell} y^{(i)} - \theta_1 \sum_{i=1}^{\ell} x^{(i)}}{\ell}$$

Для многомерной линейной регрессии:

$$\Theta = (X^T X)^{-1} X^T Y$$



Пример нахождения параметров с помощью МНК

Площадь, м²	Цена, млн.
31	3.5
82	12.5
77	7
56	5.8
52	6.8
65	8.2
90	8.9
36	3.6
142	15.1

Обучающая
выборка

Площадь, м²	Цена, млн.
72	?

Тестовая
выборка

- 1) $\sum_{i=1}^{\ell} x^{(i)} y^{(i)} = 31 * 3.5 + \dots + 142 * 15.1 = 5958.7$
- 2) $\sum_{i=1}^{\ell} x^{(i)} = 31 + 82 + \dots + 36 + 142 = 631$
- 3) $\sum_{i=1}^{\ell} y^{(i)} = 3.5 + 12.5 + \dots + 3.6 + 15.1 = 71.4$
- 4) $\sum_{i=1}^{\ell} (x^{(i)})^2 = 31^2 + 82^2 + \dots + 36^2 + 142^2 = 53239$


5)
$$\begin{cases} \theta_1 = \frac{9 * 5958.7 - 631 * 71.4}{9 * 53239 - 398161} = 0.106 \\ \theta_0 = \frac{71.4 - 0.106 * 631}{9} = 0.502 \end{cases} \Rightarrow \hat{y} = \theta_0 + \theta_1 x = 0.502 + 0.106x$$

6) $\hat{y} = 0.502 + 0.106 * 72 = 8.13 \Rightarrow$

Площадь, м²	Цена, млн.
72	8.13

Для одномерной линейной регрессии:

$$\theta_1 = \frac{\ell \sum_{i=1}^{\ell} x^{(i)} y^{(i)} - \sum_{i=1}^{\ell} x^{(i)} \sum_{i=1}^{\ell} y^{(i)}}{\ell \sum_{i=1}^{\ell} (x^{(i)})^2 - (\sum_{i=1}^{\ell} x^{(i)})^2},$$
$$\theta_0 = \frac{\sum_{i=1}^{\ell} y^{(i)} - \theta_1 \sum_{i=1}^{\ell} x^{(i)}}{\ell}$$



Содержание

- Постановка задачи, модели регрессии
- **Линейная регрессия**
 - измерение ошибки в задачах линейной регрессии
 - **обучение линейной регрессии**
 - метод наименьших квадратов
 - **метод градиентного спуска**
- Полиномиальная регрессия

Градиент функции

- Градиент функции нескольких переменных $f(x) = f(x_1, \dots, x_n)$ – n -мерный вектор, координатами которого являются частные производные этой функции по всем ее переменным:

$$\nabla f = \left(\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right)$$

- Направление вектора градиента указывает направление **наибольшего возрастания функции**
- Модуль вектора градиента равен скорости возрастания функции

График функции
 $f(x, y) = e^{-(x^2+y^2)}$






График
градиентного поля
функции $f(x, y)$



- Вектор $(-\nabla f)$ – **антиградиент**, показывающий направление **наискорейшего убывания функции**

Неформальное описание метода градиентного спуска



Формальное описание метода градиентного спуска

- **Градиентный спуск (gradient descent)** – итеративный метод нахождения локального максимума/минимума функции с помощью движения вдоль градиента/антиградиента.
- **Стратегия:** построить последовательность точек $\{x^k\}_{k=0}^{\infty}$ из $\mathbb{R}^n$ таких, что $f(x^{k+1}) < f(x^k)$, по формуле:


$$x^{k+1} = x^k - \eta \nabla f(x^k).$$

- **Алгоритм нахождения локального минимума функции:**

Вход: функция $f(x)$, $x \in \mathbb{R}^n$; размер шага η ; начальная точка x^0

Выход: локальный минимум x^* функции $f(x)$


- 1: $k = 0$
- 2: **повторять**
- 3: вычислить градиент $f(x)$ в точке x^k : $\text{grad}^k = \nabla f(x^k)$
- 4: вычислить точку x^{k+1} : $x^{k+1} = x^k - \eta \cdot \text{grad}^k$
- 5: $k = k + 1$
- 6: **пока** не выполнится условие останова
- 7: $x^* = x^k$



Градиентный спуск для обучения линейной регрессии

Необходимо найти такие веса и смещение Θ , при которых функционал ошибки $\mathcal{L}$ достигнет минимума:

$$\mathcal{L}(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a(x^{(i)}) - y^{(i)})^2 \rightarrow \min.$$



Градиентный спуск
 $x^{k+1} = x^k - \eta \nabla f(x^k)$

Обновление весов и смещения Θ :

$$\Theta = \Theta - \eta \cdot \nabla_{\Theta} \mathcal{L}$$

Вектор всех весов и смещений

$$\Theta = [\theta_0, \theta_1, \dots, \theta_d]^T$$

Вектор-градиент по весам и смещению

$$\nabla_{\Theta} \mathcal{L} = \left[\frac{\partial \mathcal{L}}{\partial \theta_0}, \frac{\partial \mathcal{L}}{\partial \theta_1}, \dots, \frac{\partial \mathcal{L}}{\partial \theta_d} \right]^T,$$

где $\frac{\partial \mathcal{L}}{\partial \theta_j} = \frac{2}{\ell} \sum_{i=1}^{\ell} (\Theta^T \cdot x^{(i)} - y^{(i)}) x_j^{(i)}$

или

$$\nabla_{\Theta} \mathcal{L} = \frac{2}{\ell} X^T (X^T \cdot \Theta - Y)$$

Пример нахождения параметров градиентным спуском

Обучающая выборка

Площадь, м²	Цена, млн.
31	3.5
82	12.5
77	7
56	5.8
52	6.8
65	8.2
90	8.9
36	3.6
142	15.1

Метод градиентного спуска


$$\Theta = \Theta - \eta \cdot \nabla_{\Theta} \mathcal{L},$$
$$\nabla_{\Theta} \mathcal{L} = \frac{2}{\ell} X^T (X^T \cdot \Theta - Y)$$

Шаг 1. Установка значений гиперпараметров и начальных значений обучаемых параметров

- Гиперпараметры:
 - скорость обучения: $\eta = 0.0001$
 - количество итераций: $n_iter = 10$
- Обучаемые параметры:
 - веса и смещение: $\Theta = [2, 1]^T$

Тестовая выборка

Площадь, м²	Цена, млн.
72	?



Пример нахождения параметров градиентным спуском

Шаг 2. Выполнение метода градиентного спуска для обучения модели

1 итерация:

- Вычисление градиента: $\nabla_{\Theta} \mathcal{L} = \frac{2}{9} \cdot \begin{bmatrix} 31 & 1 \\ \vdots & \vdots \\ 142 & 1 \end{bmatrix} \cdot \left(\begin{bmatrix} 31 & 1 \\ \vdots & \vdots \\ 142 & 1 \end{bmatrix} \cdot \begin{bmatrix} 2 \\ 1 \end{bmatrix} - \begin{bmatrix} 3.5 \\ \vdots \\ 15.1 \end{bmatrix} \right) = \begin{bmatrix} 22477.8 \\ 266.6 \end{bmatrix}$
- Обновление обучаемых параметров: $\Theta = \begin{bmatrix} 2 \\ 1 \end{bmatrix} - 0.0001 \begin{bmatrix} 22477.8 \\ 266.6 \end{bmatrix} = \begin{bmatrix} -0.25 \\ 0.97 \end{bmatrix}$

2 итерация:

- $\nabla_{\Theta} \mathcal{L} = \begin{bmatrix} -4119.2 \\ -48.7 \end{bmatrix}, \quad \Theta = \begin{bmatrix} 0.16 \\ 0.98 \end{bmatrix}$
- ...

10 итерация:

- $\nabla_{\Theta} \mathcal{L} = \begin{bmatrix} -0.007 \\ 0.158 \end{bmatrix}, \quad \Theta = \begin{bmatrix} 0.1003 \\ 0.978 \end{bmatrix}$


Шаг 3. Прогнозирование целевой переменной для объектов тестовой выборки

$$\hat{y} = 0.978 + 0.1003 * 72 = 8.2$$

Градиентный спуск


$$\Theta = \Theta - \eta \cdot \nabla_{\Theta} \mathcal{L},$$

$$\nabla_{\Theta} \mathcal{L} = \frac{2}{\ell} X^T (X^T \cdot \Theta - Y)$$




Выбор размера шага градиентного спуска (скорости обучения)

Скорость обучения η
мала




Медленная сходимость,
требуется длительное время
для достижения минимума

Скорость обучения η
оптимальна




Достижение минимума
функции за приемлемое
количество итераций и время

Скорость обучения η
высока



Промах мимо
минимума функции,
расхождение

Отражение скорости обучения на линейную регрессию



Содержание

- Постановка задачи, модели регрессии
- Линейная регрессия
 - измерение ошибки в задачах линейной регрессии
 - обучение линейной регрессии
 - метод наименьших квадратов
 - метод градиентного спуска
- **Полиномиальная регрессия**


Полиномиальная регрессия

- Полиномиальная регрессия (**polynomial regression**) – регрессионная модель зависимости целевой переменной от входных признаков данных с нелинейной функцией зависимости (полиномом, многочленом).
- Уравнение полиномиальной регрессии имеет вид:


$$y = \theta_0 + \theta_1 x + \theta_2 x^2 + \dots + \theta_d x^M,$$

где θ_0 – смещение (bias), θ_j – вес признака (weight),
 x – значение признака, d – количество входных,
 M – степень полинома.


- Степень полинома M является гиперпараметром и определяет сложность модели.




Constant Function
(degree = 0)




Linear Function
(degree = 1)




Quadratic Function
(degree = 2)



Cubic Function (deg. = 3)



Quartic Function (deg. = 4)



Quintic Function (deg. = 5)

