

Машинное обучение: как найти то, что скрыто в данных?

Поиск шаблонов

Задача «Анализ потребительской корзины»



Постановка задачи и данные

- **Задача:** определить наборы товаров, которые часто покупают совместно в супермаркете на основе истории транзакций
- **Входные данные:**
 - данные содержат 522 065 строк
 - каждая строка содержит информацию об одном товаре, приобретенном клиентом в рамках одной транзакции
 - в одной транзакции может быть несколько товаров
 - каждая строка описывается 7 атрибутами


Название	Семантика	Тип
BillNo	id транзакции (чека)	строков.
Itemname	название товара	категор.
Quantity	количество товаров	веществ.
Date	дата и время транзакции	строков.
Price	стоимость товаров	веществ.
CustomerID	id клиента	строков.
Country	страна проживания клиента	категор.

<https://www.kaggle.com/datasets/aslanahmedov/market-basket-analysis>

Пример исходных данных


csv-файл *basket_analysis.csv*

BillNo	Itemname	Quantity	Date	Price	CustomerID	Country
536365	WHITE HANGING HEART T-LIGHT HOLDER	6	01.12.10 08:26	2.55	17850	United Kingdom
536365	WHITE METAL LANTERN	6	01.12.10 08:26	3.39	17850	United Kingdom
536365	CREAM CUPID HEARTS COAT HANGER	8	01.12.10 08:26	2.75	17850	United Kingdom
536365	KNITTED UNION FLAG HOT WATER BOTTLE	6	01.12.10 08:26	3.39	17850	United Kingdom
536365	RED WOOLLY HOTTIE WHITE HEART	6	01.12.10 08:26	3.39	17850	United Kingdom




<https://www.kaggle.com/datasets/aslanahmedov/market-basket-analysis>

Этапы решения задачи поиска шаблонов



Поток работ



Шаг 1: Считывание набора данных



Dialog - 4:1 - CSV Reader (Чтение) 1.1

File

Settings Transformation Advanced Settings Limit Rows Encoding Flow Variables Job Manager Selection Memory Policy

Input location

Read from Local File System

Mode ☒ File ☐ Files in folder

File D:\Данные\Уроки по машинному обучению\Практики\Практика 5\basket_analysis.csv Browse...

Reader options

Format

Autodetect format

Column delimiter ; Row delimiter ☐ Line break ☒ Custom

Quote char " Quote escape char \

Comment char #

☒ Has column header ☐ Has RowID

☐ Support short data rows ☐ Prepend file index to RowID

Preview

The suggested column types are based on the first 10000 rows only. See 'Advanced Settings' tab.

Row ID	BillNo	Itemname	Quantity	Date	Price	Custom...	Country
Row0	536365	WHITE HANGING HEART T-LIGHT HOLDER	6	01.12.2010 8:26	2,55	17850	United Kingdom
Row1	536365	WHITE METAL LANTERN	6	01.12.2010 8:26	3,39	17850	United Kingdom
Row2	536365	CREAM CUPID HEARTS COAT HANGER	8	01.12.2010 8:26	2,75	17850	United Kingdom
Row3	536365	KNITTED UNION FLAG HOT WATER BOT...	6	01.12.2010 8:26	3,39	17850	United Kingdom
Row4	536365	RED WOOLLY HOTTIE WHITE HEART.	6	01.12.2010 8:26	3,39	17850	United Kingdom
Row5	536365	SET 7 BABUSHKA NESTING BOXES	2	01.12.2010 8:26	7,65	17850	United Kingdom
Row6	536365	GLASS STAR FROSTED T-LIGHT HOLDER	6	01.12.2010 8:26	4,25	17850	United Kingdom
Row7	536366	HAND WARMER UNION JACK	6	01.12.2010 8:28	1,85	17850	United Kingdom
Row8	536366	HAND WARMER RED POLKA DOT	6	01.12.2010 8:28	1,85	17850	United Kingdom
Row9	536367	ASSORTED COLOUR BIRD ORNAMENT	32	01.12.2010 8:34	1,69	13047	United Kingdom
Row10	536367	POPPY'S PLAYHOUSE BEDROOM	6	01.12.2010 8:34	2,1	13047	United Kingdom
Row11	536367	POPPY'S PLAYHOUSE KITCHEN	6	01.12.2010 8:34	2,1	13047	United Kingdom
Row12	536367	FELTCRAFT PRINCESS CHARLOTTE DOLL	8	01.12.2010 8:34	3,75	13047	United Kingdom
Row13	536367	IVORY KNITTED MUG COSY	6	01.12.2010 8:34	1,65	13047	United Kingdom
Row14	536367	BOX OF 6 ASSORTED COLOUR TEASPO...	6	01.12.2010 8:34	4,25	13047	United Kingdom
Row15	536367	BOX OF VINTAGE JIGSAW BLOCKS	3	01.12.2010 8:34	4,95	13047	United Kingdom
Row16	536367	BOX OF VINTAGE ALPHABET BLOCKS	2	01.12.2010 8:34	9,95	13047	United Kingdom
Row17	536367	HOME BUILDING BLOCK WORD	3	01.12.2010 8:34	5,95	13047	United Kingdom
Row18	536367	LOVE BUILDING BLOCK WORD	3	01.12.2010 8:34	5,95	13047	United Kingdom
Row19	536367	RECIPE BOX WITH METAL HEART	4	01.12.2010 8:34	7,95	13047	United Kingdom
Row20	536367	DOORMAT NEW ENGLAND	4	01.12.2010 8:34	7,95	13047	United Kingdom
Row21	536368	JAM MAKING SET WITH JARS	6	01.12.2010 8:34	4,25	13047	United Kingdom
Row22	536368	RED COAT RACK PARIS FASHION	3	01.12.2010 8:34	4,95	13047	United Kingdom

OK Apply Cancel ?

Выберите из директории файл, в котором хранится набор данных *basket_analysis.csv*

Установите параметры, необходимые для верного считывания данного csv-файла:

- Column delimiter: , (разделитель столбцов)
- Row delimiter: line break (разделитель строк)
- Has column header (считываются данные с названиями столбцов)
- Значения остальных параметров оставьте по умолчанию

Проверьте, что загруженные данные из файла отображаются в представленном виде

Шаг 1: Считывание набора данных



Dialog - 4:1 - CSV Reader (Чтение)

File

Settings Transformation **Advanced Settings** Limit Rows Encoding Flow Variables Job Manager Selection Memory Policy

1.2

Reader memory limits

☒ Limit memory per column

Maximum number of columns 8 192

Quote options

☒ Remove quotes and trim whitespaces ☐ Keep quotes

☒ Replace empty quoted strings with missing values

☐ Quotes contain no row delimiters (necessary for parallel reading)

Table specification

☒ Limit data rows scanned 600 000

When schema in file has changed

☐ Fail ☐ Use new schema ☒ Ignore (deprecated)

Number format

Thousands separator

Decimal separator .

Options for multiple files

☒ Fail if specs differ

Path column

☐ Append path column File Path

Preview

The suggested column types are based on the first 600000 rows only. See 'Advanced Settings' tab.

Row ID	S BillNo	S Itemname	I Quantity	S Date	S Price	I Custom...	S Country
Row0	536365	WHITE HANGING HEART T-LIGHT HOLDER	6	01.12.2010 8:26	2,55	17850	United Kingdom
Row1	536365	WHITE METAL LANTERN	6	01.12.2010 8:26	3,39	17850	United Kingdom
Row2	536365	CREAM CUPID HEARTS COAT HANGER	8	01.12.2010 8:26	2,75	17850	United Kingdom
Row3	536365	KNITTED UNION FLAG HOT WATER BOT...	6	01.12.2010 8:26	3,39	17850	United Kingdom
Row4	536365	RED WOOLLY HOTTIE WHITE HEART.	6	01.12.2010 8:26	3,39	17850	United Kingdom
Row5	536365	SET 7 BABUSHKA NESTING BOXES	2	01.12.2010 8:26	7,65	17850	United Kingdom
Row6	536365	GLASS STAR FROSTED T-LIGHT HOLDER	6	01.12.2010 8:26	4,25	17850	United Kingdom
Row7	536366	HAND WARMER UNION JACK	6	01.12.2010 8:28	1,85	17850	United Kingdom
Row8	536366	HAND WARMER RED POLKA DOT	6	01.12.2010 8:28	1,85	17850	United Kingdom
Row9	536367	ASSORTED COLOUR BIRD ORNAMENT	32	01.12.2010 8:34	1,69	13047	United Kingdom
Row10	536367	POPPY'S PLAYHOUSE BEDROOM	6	01.12.2010 8:34	2,1	13047	United Kingdom
Row11	536367	POPPY'S PLAYHOUSE KITCHEN	6	01.12.2010 8:34	2,1	13047	United Kingdom
Row12	536367	FELTCRAFT PRINCESS CHARLOTTE DOLL	8	01.12.2010 8:34	3,75	13047	United Kingdom
Row13	536367	IVORY KNITTED MUG COSY	6	01.12.2010 8:34	1,65	13047	United Kingdom
Row14	536367	BOX OF 6 ASSORTED COLOUR TEASPO...	6	01.12.2010 8:34	4,25	13047	United Kingdom
Row15	536367	BOX OF VINTAGE JIGSAW BLOCKS	3	01.12.2010 8:34	4,95	13047	United Kingdom
Row16	536367	BOX OF VINTAGE ALPHABET BLOCKS	2	01.12.2010 8:34	9,95	13047	United Kingdom

OK Apply Cancel ?

Далее для считывания всего набора данных во вкладке Advanced Settings увеличьте предельное значение, ограничивающее количество считываемых строк, до 600 000. Установите Limit data rows scanned = 600 000.

Шаг 2: Проведение статистического анализа и визуализация

- Выполним предварительную обработку данных для дальнейшего анализа. Для этого сначала изучим исходные данные: посчитаем статистические показатели по каждому признаку.

Statistics View 2

Визуализация статистических показателей

CSV Reader

Чтение набора данных

Dialog - 4:46 - Statistics View (Визуализация)

Statistics

Rows: 7 | Columns: 14

Name	Type	# Missing val...	# Unique val...	Minimum	Maximum	25%
BillNo	String	0	21663	?	?	?
Itemname	String	1455	4185	?	?	?
Quantity	Number (inte...	0	690	-9,600	80,995	1
Date	String	0	19641	?	?	?
Price	String	0	1285	?	?	?
CustomerID	Number (inte...	134041	4297	12,346	18,287	13,950
Country	String	0	30	?	?	?

Data

Selected Columns

Manual Wildcard Regex Type

Search

Excludes

Includes

BillNo
Itemname
Quantity
Date
Price
CustomerID
Any unknown column

Displayed Statistics

Excludes

Includes

1% Quantile
5% Quantile
10% Quantile
90% Quantile
95% Quantile
99% Quantile
Variance

Name
Type
Missing va...
Unique val...
Minimum
Maximum
25% Quantile

View

Title

Cancel Ok

Постройте и отобразите матрицу со статистическими показателями признаков. Для этого включите *все* признаки исходного набора данных.

В качестве статистических показателей оставьте те, которые указаны по умолчанию:

- Type (тип данных)
- # Missing values (кол-во пропусков)
- # Unique values (кол-во уникальных значений)
- Min, max (минимум, максимум)
- 25%, 50%, 75% quantile (первый–третий квантили)
- Mean (среднее значений)
- Mean absolute deviation, Standard deviation (среднее абсолютное и стандартное отклонения)
- Sum (сумма)
- 10 most common values (10 самых часто встречающихся значений)



Шаг 2: Удаление пропусков

Interactive View: Statistics View

Statistics

Rows: 7 | Columns: 14

Name	Type	# Missing val...	# Unique val...	Minimum	Maximum	25% Quantile	50% Quantile
BillNo	String	0	21663	②	②	②	②
Itemname	String	1455	4185	②	②	②	②
Quantity	Number (inte...	0	690	-9,600	80,995	1	3
Date	String	0	19641	②	②	②	②
Price	String	0	1285	②	②	②	②
CustomerID	Number (inte...	134041	4297	12,346	18,287	13,950	15,265
Country	String	0	30	②	②	②	②




- Статистический анализ показал, что атрибуты CustomerID и Itemname содержат пропущенные значения (см. таблицу Statistics). Поскольку алгоритмы поиска шаблонов не могут работать с данными, в которых есть пропуски, то необходимо применить один из существующих способов их обработки.
- В данной задаче объекты, значения атрибутов которых пропущены, будем удалять.


Откройте вкладку Column setting и из списка признаков выберите CustomerID и Itemname. Далее в качестве способа обработки пропущенных значений укажите Remove Row.

Шаг 2: Формирование таблицы транзакций


- Алгоритм поиска шаблонов требует, чтобы входные данные представляли собой таблицу, каждая строка которой содержит весь набор товаров, входящих в одну транзакцию. Поэтому для дальнейшей работы с исходными данными нужно их видоизменить. Для этого сгруппируем строки таблицы по id транзакции и дате.



Шаг 2: Формирование таблицы транзакций





Во вкладке Groups выберите в качестве атрибутов, по которым будут группироваться строки, BillNo и Date.



Далее во вкладке Manual Aggregation из списка признаков выберите признак Itemname, который будет агрегироваться. В качестве функции агрегации укажите Concatenate.

Шаг 2: Удаление лишних признаков



Исключите признаки, не относящиеся к наборам товаров, из выборки:

- BillNo
- Date

Шаг 2: Преобразование таблицы в необходимый вид

- Разделим списки товаров в каждой строке так, чтобы каждый товар находился в отдельной ячейке строки.

Item set			
[WHITE HANGING HEART T-LIGHT HOLDER, WHITE METAL LANTERN, CREAM CUPID HEARTS COAT HANGER]			
[HAND WARMER UNION LACK, HAND WARMER RED POLKA DOT]			

Item1	Item2	Item3
WHITE HANGING HEART T-LIGHT HOLDER	WHITE METAL LANTERN	CREAM CUPID HEARTS COAT HANGER
HAND WARMER UNION LACK	HAND WARMER RED POLKA DOT	

Statistics View

Визуализация статистических показателей

CSV Reader

Чтение набора данных

Missing Value

Удаление строк с пропусками

GroupBy

Формирование таблицы транзакций

Column Filter

Удаление ненужных признаков

Cell Splitter

Преобразование таблицы в необходимый для алгоритма вид

Dialog - 4:50 - Cell Splitter (Преобразование)

Column to split

Select a column: S Concatenate(Itemname)

☒ Remove input column

Settings

Enter a delimiter: ,

☐ Use \ as escape character

Output

☒ As list

☐ As set (remove duplicates)

☐ As new columns

Missing Value Handling

☐ Create empty string cells instead of missing string cells

Выберите столбец с наборами товаров для его разделения. Отметьте, чтобы этот столбец был исключен из выходной таблицы. Установите в качестве разделителя столбцов запятую.

Шаг 3: Поиск частых наборов

Выполните поиск частых наборов с помощью алгоритма Apriori. Для этого укажите входные списки товаров, подготовленные на предыдущих шагах, и установите $minsup = 0.01$. Далее отобразите полученные частые наборы.

Cell Splitter
Преобразование таблицы в необходимый для алгоритма вид

Association Rule Learner (Поиск частых)
7

Table View (Просмотр)
8

Table View Data

RowID	Support(0-1): Number (double)	Items Set
item ...	0.01	[HERB MARKER PARSLEY]
item ...	0.01	[HERB MARKER THYME]
item ...	0.01	[GIN & TONIC DIET GREETING CARD]
item ...	0.01	[RED RETROSPOT CHILDRENS UMBRELLA]
item ...	0.01	[SET OF 5 MINI GROCERY MAGNETS]
item ...	0.01	[LUNCH BAG RED RETROSPOT,JUMBO BAG VINTAGE LEAF]
item ...	0.01	[JUMBO BAG PINK VINTAGE PAISLEY,JUMBO BAG PINK POLKADO...
item ...	0.01	[LUNCH BAG SPACEBOY DESIGN,LUNCH BAG BLACK SKULL.,LUNC...
item ...	0.01	[METAL SIGN EMPIRE TEA]
item ...	0.01	[HERB MARKER BASIL]
item ...	0.01	[SET 12 KIDS WHITE CHALK STICKS]
item ...	0.01	[TRAVEL CARD WALLET SUKI]
item ...	0.01	[ZINC HERB GARDEN CONTAINER]
item ...	0.01	[WHITE HANGING HEART T-LIGHT HOLDER,LUNCH BAG CARS BLUE]
item ...	0.01	[60 CAKE CASES DOLLY GIRL DESIGN,PACK OF 72 RETROSPOT CA...

Dialog - 4:2 - Association Rule Learner (Поиск частых)
7

Options | Flow Variables | Job Manager Selection | Memory Policy

Itemset Mining

Column containing transactions: [...] Concatenate(Itemname)_SplitResultList

Minimum support (0-1): 0,01

Underlying data structure: ARRAY

Output

Itemset type: CLOSED

Maximal itemset length: 10

Association Rules

☐ Output association rules

Minimum confidence: 0,8

Dialog - 4:52 - Table View (Просмотр)
8

Table View

Rows: 972 | Columns: 2

Data

Displayed columns: Manual Wildcard Regex Type

Search: Aa

Excludes

No columns in this list

Includes

Support(0-1): Items

☐ Show row numbers

☒ Show RowIDs

View

Title: Table View


☒ Show table size

☒ Show column data types in header


☐ Pagination

Cancel Ok

Шаг 3: Поиск шаблонов




Создайте отдельную ветку для поиска шаблонов в данных алгоритмом Apriori. Для поиска шаблонов дополнительно установите $minconf = 0.7$. Минимальное значение поддержки оставьте таким же. Далее отобразите полученные шаблоны.




The screenshot shows the 'Table View' dialog box. The 'Table View' tab is selected. The table displays the results of the Apriori algorithm. The columns are: RowID, Support, Confidence, Lift, Consequ..., implies, and Item Set. The table is labeled with a red '10'.

RowID	Support	Confidence	Lift	Consequ...	implies	Item Set
rule0	0.01	0.725	8.386	JUMBO BAG ...	<--	[JUMBO E
rule1	0.01	0.763	56.691	REGENCY MI...	<--	[REGENC'
rule2	0.01	0.751	56.691	REGENCY SU...	<--	[REGENC'
rule3	0.01	0.745	13.857	LUNCH BAG ...	<--	[LUNCH E
rule4	0.01	0.781	9.028	JUMBO BAG ...	<--	[LUNCH E
rule5	0.01	0.743	8.593	JUMBO BAG ...	<--	[JUMBO S
rule6	0.01	0.77	8.9	JUMBO BAG ...	<--	[JUMBO E
rule7	0.01	0.734	10.553	LUNCH BAG ...	<--	[LUNCH E
rule8	0.01	0.734	14.617	LUNCH BAG ...	<--	[LUNCH E
rule9	0.01	0.723	29.444	WOODEN HE...	<--	[WOODEN
rule10	0.011	0.811	48.086	POPPY'S PLA...	<--	[POPPY'S
rule11	0.011	0.776	45.373	CHILDRENS ...	<--	[CHILDRE
rule12	0.011	0.841	50.857	REGENCY TE...	<--	[REGENC'
rule13	0.011	0.852	46.018	POPPY'S PLA...	<--	[POPPY'S
rule14	0.012	0.779	16.584	AI ARM CI OC	<--	[AI ARM C

Шаг 3: Запись полученных результатов



Для сохранения результатов создайте пустой csv-файл *basket_analysis_sets.csv* и укажите путь до этого файла. Для экспорта результатов в csv-файл установите параметры, приведенные на скриншоте.





Аналогичные действия проделайте для второй ветки, сохранив результаты в файле *basket_analysis_rules.csv*.

Шаг 4: Исследование влияния значения поддержки на результаты

- Проведем две серии экспериментов, в которых:
 - 1) исследуем влияние различных значений $minsup$ на количество частых наборов;
 - 2) исследуем влияние различных значений $minconf$ при фиксированном значении sup на количество шаблонов.
- Для проведения первого эксперимента необходимо выполнить проход по различным значениям поддержки $minsup = [0.01, 0.02, 0.03, 0.04, 0.05]$. Для этого необходим цикл, в котором будет выполняться поиск частых наборов при текущем значении поддержки и подсчет их количества.




Для каждого эксперимента создадим отдельную ветку.



Определите начало цикла.
Установите следующие значения параметров для выполнения итераций цикла по sup :


- From: 0.01 (начальное значение счетчика)
- To: 0.05 (конечное значение счетчика)
- Step: 0.01 (шаг счетчика)
- Loop variable is: double (тип данных счетчика)

Шаг 4: Исследование влияния значения поддержки на результаты






Далее выполняется поиск частых наборов. Гиперпараметром алгоритма является значение поддержки *sup*. Для задания значения поддержки используйте текущее значение счетчика цикла. Для этого во вкладке Flow Variables для MIN_SUPPORT задайте loop_value.






Шаг 4: Исследование влияния значения поддержки на результаты



- После выполнения алгоритма Apriori вычислите количество найденных наборов. Установите в качестве агрегатной функции Occurrence count.
- На этом итерация цикла завершается для текущего *sup*, и цикл продолжается, пока не достигнуто последнее значение *sup*. Установите конец цикла, задав ему параметры, указанные на рисунке 18.
- После завершения цикла отобразим количество найденных частых наборов при различных *sup* на графике. Параметры, которые необходимо задать, показаны на рисунке 19.



Шаг 4: Исследование влияния значения достоверности на результаты



- Вторая серия экспериментов отличается от первой тем, что исследуется влияние различных значений достоверности $minconf$ на количество шаблонов при фиксированном значении поддержки sup .
- Создайте отдельную ветку, в которой будут перебираться значения $minconf = [0.5, 0.6, 0.7, 0.8, 0.9]$. При этом значение поддержки будет постоянным и равно 0.01. Все параметры, которые необходимо установить, показаны на рисунках 20, 21, 24. Остальные шаги ничем не отличаются от первой серии экспериментов.

Шаг 5: Сдача практической работы

- После того, как пройдены все шаги и реализован поток данных, выполните экспорт получившегося потока работ из KNIME и прикрепите его в электронный ЮУрГУ в качестве ответа на задание



Практика 3. Разбор задачи (поиск шаблонов)