

Машинное обучение: как найти то, что скрыто в данных?


Линейная регрессия

Задача «Оценка рыночной стоимости квартиры»



Постановка задачи и данные

- **Задача:** определить рыночную стоимость квартиры в Челябинске на основе объявлений о продажах
- **Входные данные:**
 - реальные объявления о продаже квартир в Челябинске, размещенные на сервисе Домклик по поиску, продаже и аренде недвижимости
 - данные хранятся в csv-файле *apartment_sale.csv*, который содержит информацию о 100 объявлениях



Данные


- Атрибуты

Признак	Семантика
<i>area</i>	площадь квартиры, м ²
<i>floor</i>	этаж
<i>rooms</i>	число комнат
<i>year_built</i>	год постройки дома
<i>construction_type</i>	тип строительства дома
<i>district</i>	район города
<i>price</i>	стоимость, млн руб. (целевая переменная)


- Файл в формате csv *apartment_sale.csv*

area	floor	rooms	year_built	construction_type	district	price
35	3	1	1973	prefabricated	Kalininsky	3.4
64	8	3	1987	prefabricated	Kalininsky	6.5
90	18	2	2011	brick	Kalininsky	14
53	3	1	2014	brick	Kalininsky	7
53	7	2	1988	prefabricated	Kalininsky	4.5
51	10	2	1987	prefabricated	Kalininsky	4.1
106	10	3	2001	prefabricated	Kalininsky	10.5
40	8	1	1086	prefabricated	Kalininsky	4.2
53	1	2	1990	prefabricated	Kalininsky	5
103	3	3	2002	prefabricated	Kalininsky	8.6
50	4	2	1991	prefabricated	Kalininsky	5.1
...	...	...	...	...	...	...



Этапы решения задачи регрессии



Поток работ



Шаг 1: Считывание набора данных




Выберите из директории файл, в котором хранится исходный набор данных *apartment_sale.csv*

Установите параметры, необходимые для верного считывания данного csv-файла:

- Column delimiter: , (разделитель столбцов)
- Row delimiter: line break (разделитель строк)
- Has column header (считываются данные с названиями столбцов)
- Значения остальных параметров оставьте по умолчанию



Проверьте, что загруженные данные из файла отображаются в представленном виде

Шаг 2: Проведение статистического анализа и визуализация



Отобразите матрицу со статистическими показателями признаков и матрицу с точечными диаграммами между всеми парами признаков. Задайте все признаки исходного набора данных для построения матриц.

- Перед решением задачи регрессии необходимо изучить исходные данные.
- Данный шаг включает в себя:
 - определение типов признаков;
 - проверку наличия пропущенных значений;
 - проверку наличия выбросов;
 - оценку распределения данных;
 - визуализацию данных;
 - ...




Шаг 2: Корреляционный анализ

- Отбор важных признаков будем выполнять через вычисление коэффициента корреляции Пирсона между признаками и целевой переменной.
- Коэффициент корреляции Пирсона характеризует существование линейной зависимости между двумя признаками X_1 и X_2 и вычисляется как

$$r = \frac{\sum_{i=1}^n (x_1^{(i)} - \bar{X}_1)(x_2^{(i)} - \bar{X}_2)}{\sqrt{\sum_{i=1}^n (x_1^{(i)} - \bar{X}_1)^2 \cdot \sum_{i=1}^n (x_2^{(i)} - \bar{X}_2)^2}},$$

где $x_1^{(i)}$ и $x_2^{(i)}$ – значения признаков X_1 и X_2 у объекта $x^{(i)}$,
 $\bar{X}_1$ и $\bar{X}_2$ – средние значения признаков X_1 и X_2 ,
 n – количество объектов в наборе данных.

- Коэффициент корреляции Пирсона принимает значения от -1 до 1 :
 - при $r = 1$ идеальная положительная корреляция
 - при $r = 0$ отсутствие корреляции
 - при $r = -1$ идеальная отрицательная корреляция




Для нахождения матрицы корреляции выберите числовые признаки и целевую переменную, исключив из рассмотрения категориальные.

Установите следующие входные параметры:

- Output column pairs: Include all column pairs
- p-value: two-sided

Шаг 2: Корреляционный анализ





Для отображения вычисленной матрицы корреляции в виде тепловой карты установите параметры:

- Horizontal dimension: First column name (ось OX , на которой откладываются признаки)
- Vertical dimension: Second column name (ось OY , на которой откладываются признаки)
- Aggregation: None (способ агрегации)
- Value dimension: Correlation value (значения тепловой карты)


Матрица визуализируется не полностью, а только нижний ее треугольник. Это справедливо, поскольку данная матрица симметрична относительно главной диагонали, т.е. $r(X_i, X_j) = r(X_j, X_i)$.

Например, $r(area, price) = r(price, area)$.

Шаг 2: Удаление признаков




Коэффициент корреляции между целевой переменной `price` и входным признаком `floor` равен 0.08. Между ними отсутствует линейная зависимость. Исключите признак `floor` из набора данных.




Сильная корреляция между признаками `area` и `rooms`.

Чтобы избежать мультиколлинеарности, один из них лучше удалить (например, `rooms`).





Шаг 2: Кодирование категориальных признаков

- Поскольку среди входных признаков есть категориальные, то их необходимо закодировать, преобразовать в числовые признаки.
- Бинарное кодирование (one-hot encoding)** – один из методов кодирования категориальных признаков, которое заменяет каждое значение категориального признака на столбец бинарных значений, где 1 указывает на присутствие значения признака у объекта, 0 – на его отсутствие.





c_1, c_2, c_3 – категории входного признака X_j

c_1, c_2, c_3 – новые бинарные признаки категорий



Для one-hot кодирования укажите все категориальные признаки, которыми описываются объекты в наборе данных.

Шаг 2: Разделение данных



Разделите набор данных на обучающую и тестовую выборки в соотношении 80: 20, установив параметр $\text{Relative}[\%] = 80$.


Разделение данных на две выборки должно быть случайным. Случайное разделение означает, что каждый объект данных имеет одинаковый шанс попасть в обучающую или тестовую выборку. Для этого выберите среди всех возможных способов разбиения **Draw randomly**.

Шаг 2: Масштабирование признаков

- Для улучшения стабильности модели и уравнивания степени влияния признаков на процесс обучения все признаки в наборе данных должны быть приведены к одному диапазону значений.
- Min-max масштабирование (min-max scaling)** – процесс приведения каждого признака к диапазону от 0 до 1:


$$X_{scale} = \frac{X - X_{min}}{X_{max} - X_{min}},$$

где X_{min} и X_{max} – минимальное и максимальное значения признака X соответственно.




Выберите все признаки обучающей выборки для их масштабирования.

В качестве метода масштабирования выберите Min-max и задайте диапазон значений от 0 до 1.





Масштабирование признаков для тестовой выборки не требует установки параметров. Поэтому все настройки этого узла, не связанные с вычислениями, оставьте по умолчанию.

Шаг 3: Обучение модели и прогноз целевой переменной



Измените название целевой переменной, спрогнозированной обученной моделью линейной регрессии, на predicted price.



Для обучения модели линейной регрессии градиентным спуском установите следующие начальные гиперпараметры:



- `debug = False` (без отладки)
- `dontNormalize = True` (без нормализации)
- `dontReplaceMissing = True` (без замены пропущенных значений)
- `epochs = 100` (количество эпох)
- `epsilon = 0.1` (критерий останова)
- `lambda = 1.0E-4` (скорость регуляризации)
- `learningRate = 0.01` (скорость обучения)
- `lossFunction = Squared loss (regression)` (функция потерь)
- `seed = 1` (случайное зерно)
- `target column = price` (целевая переменная)

Шаг 4: Демасштабирование признаков


- Min-max демасштабирование (Min-max descaling)** – обратная операция min-max масштабирования, которая приводит каждый признак к исходному диапазону значений:

$$X = X_{max} \cdot X_{scale} - X_{min} \cdot (X_{scale} - 1),$$


где X_{min} и X_{max} – минимальное и максимальное значения признака X соответственно.




Удалите из тестовой выборки признак price.



Переименуйте признак predicted price на price.




Для демасштабирования признаков параметры оставьте по умолчанию.



Замените название признака price на predicted price.


Шаг 4: Демасштабирование целевой переменной

- Добавьте к исходной тестовой выборке признак predicted price, который был получен моделью. Для этого выполните операцию inner join (слияние) над двумя таблицами: исходной тестовой выборкой и таблицей с прогнозированной целевой переменной.



Установите операцию соединения Matching rows.

Установите в качестве левой таблицы исходную тестовую выборку и выберите все ее столбцы для включения в результирующую таблицу.




Установите в качестве правой таблицы таблицу с прогнозированной целевой переменной и выберите столбец predicted price для включения его в результирующую таблицу.

Установите параметры соединения:

- Merge join columns (отметить)
- Do not execute (выбрать)
- Split join result (не отмечать)
- RowIDs: Create new (выбрать)

Шаг 5: Вычисление метрик точности





Отобразите матрицу с вычисленными метриками точности, установив следующие параметры:


- Includes: Metric value (включение столбца со значениями метрик)
- Show row number (отображение столбца с порядковыми номерами метрик)
- Show RowIDs (отображение столбца с названиями метрик)

Оцените точность модели линейной регрессии, вычислив метрики точности. Установите в качестве reference column (столбец с истинными значениями целевой переменной) переменную price и Predicted column – predicted price.

Измените название столбца, в котором будут храниться значения вычисленных метрик, на Metric value.




Шаг 6: Запись полученных результатов



Для сохранения результатов создайте пустой csv-файл *apartment_sale_results.csv* и укажите путь до этого файла.

Для экспорта результатов в csv-файл установите параметры:

- Column delimiter: , (разделитель столбцов)
- Row delimiter: System default (разделитель строк)
- Write column header (записываются названия столбцов в выходной файл)
- Write RowID (исключается столбец с порядковыми номерами объектов из записи в выходной файл)



Шаг 7: Сдача практической работы

- После того, как пройдены все шаги и реализован поток данных, выполните экспорт получившегося потока работ из KNIME и прикрепите его в электронный ЮУрГУ в качестве ответа на задание



Практика 2. Разбор задачи (регрессия)