

Машинное обучение: как найти то, что скрыто в данных?

Классификация

Задача «Прогнозирование дохода»



Постановка задачи и данные

- **Задача:** классифицировать граждан по их годовому доходу, который может быть либо ниже, либо выше \$50 000
- **Входные данные:**
 - результаты переписи населения 1994 года в США с информацией о работающих гражданах, которым старше 16 лет
 - данные представлены в двух csv-файлах *adult_train.csv* и *adult_test.csv*, которые содержат обучающую и тестовую выборки соответственно
 - обучающая и тестовая выборки состоят из 32 561 и 16 281 объектов
 - каждый объект определяется 15 *атрибутами*

<https://www.kaggle.com/datasets/uciml/adult-census-income>

Семантика атрибутов

№	Название	Семантика	№	Название	Семантика
1	Age	возраст	9	Race	расовая принадлежность
2	Workclass	рабочий класс	10	Sex	пол
3	Fnlwgt	число людей, которых представляет запись	11	Capital-gain	прирост капитала
4	Education	образование	12	Capital-loss	убыток капитала
5	Education-num	длительность обучения	13	Hours-per-week	количество рабочих часов в неделю
6	Marital-status	семейное положение	14	Country	страна
7	Occupation	профессия	15	Outcome	доход
8	Relationship	семейное отношение			

Типы и значения атрибутов

№	Название	Тип	Допустимые значения	№	Название	Тип	Допустимые значения
1	Age	Колич.	$Age \in \mathbb{R}$	9	Race	Категор.	$Race = \{White, \dots, Other\}$ $ Race = 5$
2	Workclass	Категор.	$Workclass = \{Private, \dots, State - gov\}$ $ Workclass = 7$	10	Sex	Бинарн.	$Sex = \{Male, Female\}$
3	Fnlwgt	Колич.	$Fnlwgt \in \mathbb{R}$	11	Capital-gain	Колич.	$Capital - gain \in \mathbb{R}$
4	Education	Порядк.	$Education = \{HS - grad, \dots, Masters\}$ $ Education = 16$	12	Capital-loss	Колич.	$Capital - loss \in \mathbb{R}$
5	Education-num	Колич.	$Education - num \in \mathbb{R}$	13	Hours-per-week	Колич.	$Hours - per - week \in \mathbb{R}$
6	Marital-status	Категор.	$Material - status = \{Divorced, \dots, Widowed\}$ $ Material - status = 7$	14	Country	Категор.	$Country = \{Mexico, \dots, Italy\}$ $ Country = 41$
7	Occupation	Категор.	$Occupation = \{Prof - specialty, \dots, Sales\}$ $ Occupation = 14$	15	Outcome	Бинарн.	$Outcome = \{ \leq 50K, > 50K \}$
8	Relationship	Категор.	$Relationship = \{Husband, \dots, Wife\}$ $ Relationship = 6$	$ Attribute $ – мощность (размер) множества или количество элементов в множестве			

Пример исходных данных


- Обучающая выборка *adult_train.csv*

Age	Workclass	Fnlwgt	Education	Education-num	Marital-status	Occupation	Relationship	Race	Sex	Capital-gain	Capital-loss	Hours-per-week	Country	Outcome
39	State-gov	77516	Bachelors	13	Never-married	Adm-clerical	Not-in-family	White	Male	2174	0	40	United-States	<=50K
50	Self-emp-not-inc	83311	Bachelors	13	Married-civ-spouse	Exec-managerial	Husband	White	Male	0	0	13	United-States	<=50K
38	Private	215646	HS-grad	9	Divorced	Handlers-cleaners	Not-in-family	White	Male	0	0	40	United-States	<=50K
53	Private	234721	11 th	7	Married-civ-spouse	Handlers-cleaners	Husband	Black	Male	0	0	40	United-States	<=50K
28	Private	338409	Bachelors	13	Married-civ-spouse	Prof-specialty	Wife	Black	Female	0	0	40	Cuba	<=50K


- Тестовая выборка *adult_test.csv*

25	Private	226802	11th	7	Never-married	Machine-op-inspct	Own-child	Black	Male	0	0	40	United-States	<=50K
38	Private	89814	HS-grad	9	Married-civ-spouse	Farming-fishing	Husband	White	Male	0	0	50	United-States	<=50K
28	Local-gov	336951	Assoc-acdm	12	Married-civ-spouse	Protective-serv	Husband	White	Male	0	0	40	United-States	>50K

Этапы решения задачи классификации



Поток работ



Шаг 1: Считывание обучающей выборки



Чтение
обучающей
выборки

Dialog - 5:62 - CSV Reader (Чтение)

File

Settings Transformation Advanced Settings Limit Rows Encoding Flow Variables Job Manager Selection Memory Policy

Input location

Read from Local File System

Mode ☒ File ☐ Files in folder

File D:\Данные\Лекции по машинному обучению\Практики\Практика 3\adult_train.csv Browse...

Reader options

Format

Autodetect format

Column delimiter , Row delimiter ☐ Line break ☒ Custom Quote char " Quote escape char \# Comment char #

☒ Has column header ☐ Has RowID ☐ Support short data rows ☐ Prepend file index to RowID

Preview

The suggested column types are based on the first 10000 rows only. See 'Advanced Settings' tab.

Row ID	Age	Workclass	Fnlwgt	Education	Educat...	Marital...	Occup...	Relatio...	Race	Sex	Capital...	Capital...
Row0	39	State-gov	77516	Bachelors	13	Never-married	Adm-clerical	Not-in-family	White	Male	2174	0
Row1	50	Self-emp-no...	83311	Bachelors	13	Married-div...	Exec-manag...	Husband	White	Male	0	0
Row2	38	Private	215646	HS-grad	9	Divorced	Handlers-de...	Not-in-family	White	Male	0	0
Row3	53	Private	234721	11th	7	Married-div...	Handlers-de...	Husband	Black	Male	0	0
Row4	28	Private	338409	Bachelors	13	Married-div...	Prof-specialty	Wife	Black	Female	0	0
Row5	37	Private	284582	Masters	14	Married-div...	Exec-manag...	Wife	White	Female	0	0
Row6	49	Private	160187	9th	5	Married-spo...	Other-service	Not-in-family	Black	Female	0	0
Row7	52	Self-emp-no...	209642	HS-grad	9	Married-div...	Exec-manag...	Husband	White	Male	0	0
Row8	31	Private	45781	Masters	14	Never-married	Prof-specialty	Not-in-family	White	Female	14084	0
Row9	42	Private	159449	Bachelors	13	Married-div...	Exec-manag...	Husband	White	Male	5178	0
Row10	37	Private	280464	Some-college	10	Married-div...	Exec-manag...	Husband	Black	Male	0	0
Row11	30	State-gov	141297	Bachelors	13	Married-div...	Prof-specialty	Husband	Asian-Pac-Is...	Male	0	0
Row12	23	Private	122272	Bachelors	13	Never-married	Adm-clerical	Own-child	White	Female	0	0
Row13	32	Private	205019	Assoc-acdm	12	Never-married	Sales	Not-in-family	Black	Male	0	0
Row14	40	Private	121772	Assoc-voc	11	Married-div...	Craft-repair	Husband	Asian-Pac-Is...	Male	0	0
Row15	34	Private	245487	7th-8th	4	Married-div...	Transport-m...	Husband	Amer-Indian...	Male	0	0
Row16	25	Self-emp-no...	176756	HS-grad	9	Never-married	Farming-fish...	Own-child	White	Male	0	0
Row17	32	Private	186824	HS-grad	9	Never-married	Machine-op...	Unmarried	White	Male	0	0
Row18	38	Private	28887	11th	7	Married-div...	Sales	Husband	White	Male	0	0
Row19	43	Self-emp-no...	292175	Masters	14	Divorced	Exec-manag...	Unmarried	White	Female	0	0
Row20	40	Private	193524	Doctorate	16	Married-div...	Prof-specialty	Husband	White	Male	0	0
Row21	54	Private	302146	HS-grad	9	Separated	Other-service	Unmarried	Black	Female	0	0

OK Apply Cancel ?

Выберите из директории файл, в котором хранится обучающая выборка *adult_train.csv*


Установите параметры, необходимые для верного считывания данного csv-файла:

- Column delimiter: , (разделитель столбцов)
- Row delimiter: line break (разделитель строк)
- Has column header (считываются данные с названиями столбцов)
- Значения остальных параметров оставьте по умолчанию

Проверьте, что загруженные данные из файла отображаются в представленном виде

Шаг 2: Проведение статистического анализа и визуализация

- Выполним предварительную обработку данных для дальнейшего их анализа. Для этого сначала изучим исходные данные: посчитаем статистические показатели по каждому признаку.



Dialog - 5:71 - Statistics View (Визуализация)

Statistics

Rows: 15 | Columns: 14

Name	Type	# Missing val...	# Unique val...	Minimum	Maximum	
Age	Number (inte...	0	73	17	90	28
Workclass	String	0	9	?	?	?
Fnlwgt	Number (inte...	0	21648	12,285	1,484,705	117,8
Education	String	0	16	?	?	?
Education-num	Number (inte...	0	16	1	16	9
Marital-status	String	0	7	?	?	?
Occupation	String	0	15	?	?	?
Relationship	String	0	6	?	?	?
Race	String	0	5	?	?	?
Sex	String	0	2	?	?	?
Capital-gain	Number (inte...	0	119	0	99,999	0
Capital-loss	Number (inte...	0	92	0	4,356	0
Hours-per-we...	Number (inte...	0	94	1	99	40
Country	String	0	42	?	?	?
Outcome	String	0	2	?	?	?

Data

Selected Columns

Manual Wildcard Regex Type

Search Aa

Excludes

Includes

Age

Workclass

Fnlwgt

Education

Education-n...

Marital-status

Any unknown column

Displayed Statistics

Excludes

Includes

1% Quantile

5% Quantile

10% Quantile

90% Quantile

95% Quantile

99% Quantile

Variance

Name

Type

Missing va...

Unique val...

Minimum

Maximum

25% Quantile

View

Title

Cancel Ok

Постройте и отобразите матрицу со статистическими показателями признаков. Для этого включите *все* признаки исходного набора данных.

В качестве статистических показателей оставьте те, которые указаны по умолчанию:

- Type (тип данных)
- # Missing values (кол-во пропусков)
- # Unique values (кол-во уникальных значений)
- Min, max (минимум, максимум)
- 25%, 50%, 75% quantile (первый–третий квантили)
- Mean (среднее значений)
- Mean absolute deviation, Standard deviation (среднее абсолютное и стандартное отклонения)
- Sum (сумма)
- 10 most common values (10 самых часто встречающихся значений)

Шаг 2: Удаление строк с пропущенными значениями



- Из описания набора данных следует, что в данных имеются пропущенные значения, которые обозначены символом "?".
- Выполнив сортировку по возрастанию значений в каждом столбце можно заметить, что существуют три атрибута, в которых есть пропущенные значения:
 - Workclass;
 - Occupation;
 - Country.

File Table - 5:62 - CSV Reader (Чтение)

Table "default" - Rows: 32561 Spec - Columns: 15 Properties Flow Variables

Row ID	Age	Workclass	Fnlwgt	Education	Education-Num	Marital-Status	Occupation	Relationship	Race	Sex	Capital-Gain	Capital-Loss	Hours-Per-Week	Country	Outcome
Row61	32	?	293936	7th-8th	4	Married-spo...	?	Not-in-family	White	Male	0	0	40	?	<=50K
Row297	39	?	157443	Masters	14	Married-civ...	?	Wife	Asian-Pac-Is...	Female	3464	0	40	?	<=50K
Row1152	24	?	35533	Some-college	10	Never-married	?	Not-in-family	White	Male	0	0	40	?	<=50K
Row1676	64	?	168340	HS-grad	9	Married-civ...	?	Husband	White	Male	0	0	40	?	>50K
Row2513	47	?	174525	HS-grad	9	Married-civ...	?	Husband	White	Male	3942	0	40	?	<=50K
Row3131	25	?	237865	Some-college	10	Never-married	?	Own-child	Black	Male	0	0	40	?	<=50K
Row3579	21	?	180303	Bachelors	13	Never-married	?	Not-in-family	Asian-Pac-Is...	Male	0	0	25	?	<=50K
Row3834	32	?	169886	Bachelors	13	Never-married	?	Not-in-family	White	Female	0	0	20	?	<=50K
Row6059	35	?	163582	10th	6	Divorced	?	Unmarried	White	Female	0	0	16	?	<=50K
Row7862	29	?	125159	Some-college	10	Never-married	?	Not-in-family	Black	Male	0	0	36	?	<=50K
Row9616	32	?	647882	HS-grad	9	Married-civ...	?	Husband	White	Male	0	0	40	?	<=50K
Row11614	35	?	103710	Bachelors	13	Divorced	?	Unmarried	White	Female	0	0	16	?	<=50K
Row12996	37	?	122265	HS-grad	9	Divorced	?	Not-in-family	Asian-Pac-Is...	Female	0	0	42	?	<=50K
Row16488	33	?	119918	Bachelors	13	Never-married	?	Not-in-family	Black	Male	0	0	45	?	<=50K
Row16838	28	?	149646	Some-college	10	Divorced	?	Own-child	White	Female	0	0	20	?	<=50K
Row18615	27	?	251854	Bachelors	13	Married-civ...	?	Wife	Black	Female	0	0	35	?	>50K
Row20333	69	?	199591	Prof-school	15	Married-civ...	?	Wife	White	Female	0	0	25	?	<=50K
Row20480	55	?	315027	7th-8th	4	Married-civ...	?	Husband	White	Male	0	0	40	?	<=50K
Row23729	41	?	211873	Assoc-voc	11	Married-civ...	?	Wife	White	Female	0	1628	5	?	<=50K
Row23915	24	?	311949	HS-grad	9	Never-married	?	Not-in-family	Asian-Pac-Is...	Female	0	0	45	?	<=50K
Row25359	38	?	94559	Bachelors	13	Married-civ...	?	Wife	Other	Female	7688	0	50	?	>50K
Row26296	68	?	285869	7th-8th	4	Widowed	?	Not-in-family	White	Female	0	1668	40	?	<=50K
Row26363	48	?	353824	Some-college	10	Married-civ...	?	Husband	White	Male	0	0	40	?	>50K
Row28194	27	?	133359	Bachelors	13	Married-spo...	?	Not-in-family	White	Male	0	0	50	?	<=50K
Row28688	20	?	200061	Some-college	10	Never-married	?	Own-child	White	Female	0	0	40	?	<=50K
Row30369	20	?	250037	Some-college	10	Never-married	?	Own-child	White	Female	0	0	18	?	<=50K
Row32525	81	?	120478	Assoc-voc	11	Divorced	?	Unmarried	White	Female	0	0	1	?	<=50K
Row1711	47	Federal-gov	168191	Some-college	10	Married-civ...	Craft-repair	Husband	White	Male	0	0	40	?	<=50K
Row4197	51	Federal-gov	45334	Some-college	10	Married-civ...	Protective-s...	Husband	Asian-Pac-Is...	Male	0	0	70	?	<=50K
Row5709	37	Federal-gov	129573	Doctorate	16	Married-civ...	Prof-specialty	Husband	White	Male	0	0	72	?	>50K
Row6395	24	Federal-gov	215115	Bachelors	13	Never-married	Tech-support	Own-child	White	Female	0	0	40	?	<=50K
Row6844	37	Federal-gov	325538	Masters	14	Married-civ...	Prof-specialty	Husband	White	Male	0	0	40	?	>50K
Row7284	40	Federal-gov	163215	Bachelors	13	Never-married	Prof-specialty	Not-in-family	White	Female	0	0	40	?	<=50K
Row7615	46	Federal-gov	233555	HS-grad	9	Divorced	Adm-clerical	Unmarried	Black	Female	0	0	40	?	<=50K
Row9580	35	Federal-gov	35309	Bachelors	13	Never-married	Tech-support	Not-in-family	Asian-Pac-Is...	Male	0	0	28	?	<=50K
Row13768	37	Federal-gov	81353	HS-grad	9	Divorced	Prof-specialty	Unmarried	Asian-Pac-Is...	Female	0	0	40	?	<=50K
Row15734	51	Federal-gov	215948	Some-college	10	Married-civ...	Handlers-de...	Husband	Other	Male	0	0	40	?	<=50K
Row18412	43	Federal-gov	155996	Prof-school	15	Married-civ...	Prof-specialty	Husband	Asian-Pac-Is...	Male	0	2415	55	?	>50K

Шаг 2: Удаление строк с пропущенными значениями



Обработка пропущенных значений будет заключаться в удалении строк, которые содержат "?" хотя бы в одном из трех столбцов: Workclass, Occupation или Country. Для этого установите следующие условия:


OR

Workclass == ?
Occupation == ?
Country == ?.

Чтобы исключить строки с пропущенными значениями из обучающей выборки выберите Exclude by query.


Шаг 2: Удаление дубликатов

- Кроме пропущенных значений, набор данных содержит дубликаты.
- Дубликат – это две или более повторяющиеся записи, которые имеют одинаковые значения для всех признаков.
- Такие записи могут возникать в результате ошибки, связанной с человеческим фактором, или по причине сбора данных из разных источников, которые содержат одинаковые значения.
- Удаление дубликатов является важным и необходимым этапом в очистке данных, поскольку помогает повысить эффективность, уменьшить шум и улучшить точность модели.



Включите все атрибуты для поиска дубликатов. Среди найденных дубликатов строк удалите все, кроме первой строки, установив следующие два параметра:


- Duplicate rows: Remove duplicate rows
- Row chosen in case of duplicate: First



Шаг 2: Удаление дубликатов

- В обучающей выборке содержится 45 дубликатов

Row ID	I	Colu...	S	Colu...	I	Colu...	S	Column5	S	Column6	S	Column7	S	Colu...	S	Colu...	I	Colu...	I	Colu...	S	Column...	S	Colu.
Row17673	19	Private	97261	HS-grad	9	Never-married	Farming-fishi...	Not-in-fam...	White	Male	0	0	40	United-Stat...	<=50K									
Row18698	19	Private	97261	HS-grad	9	Never-married	Farming-fishi...	Not-in-fam...	White	Male	0	0	40	United-Stat...	<=50K									
Row6990	19	Private	138153	Some-coll...	10	Never-married	Adm-clerical	Own-child	White	Female	0	0	10	United-Stat...	<=50K									
Row21318	19	Private	138153	Some-coll...	10	Never-married	Adm-clerical	Own-child	White	Female	0	0	10	United-Stat...	<=50K									
Row15189	19	Private	146679	Some-coll...	10	Never-married	Exec-manage...	Own-child	Black	Male	0	0	30	United-Stat...	<=50K									
Row21490	19	Private	146679	Some-coll...	10	Never-married	Exec-manage...	Own-child	Black	Male	0	0	30	United-Stat...	<=50K									
Row3917	19	Private	251579	Some-coll...	10	Never-married	Other-service	Own-child	White	Male	0	0	14	United-Stat...	<=50K									
Row31993	19	Private	251579	Some-coll...	10	Never-married	Other-service	Own-child	White	Male	0	0	14	United-Stat...	<=50K									
Row5805	20	Private	107658	Some-coll...	10	Never-married	Tech-support	Not-in-fam...	White	Female	0	0	10	United-Stat...	<=50K									
Row11631	20	Private	107658	Some-coll...	10	Never-married	Tech-support	Not-in-fam...	White	Female	0	0	10	United-Stat...	<=50K									




- После очистки данных от дубликатов осталось 22 уникальных объекта

Row ID	I	Colu...	S	Colu...	I	Colu...	S	Column5	S	Column6	S	Column7	S	Colu...	S	Colu...	I	Colu...	I	Colu...	I	Colu...	S	Column...	S	Colu...
Row18698	19		Private	97261	HS-grad	9		Never-married	Farming-fishing	Not-in-family	White	Male	0	0	40	United-States	<= 50K									
Row21318	19		Private	138153	Some-coll...	10		Never-married	Adm-clerical	Own-child	White	Female	0	0	10	United-States	<= 50K									
Row21490	19		Private	146679	Some-coll...	10		Never-married	Exec-manage...	Own-child	Black	Male	0	0	30	United-States	<= 50K									
Row31993	19		Private	251579	Some-coll...	10		Never-married	Other-service	Own-child	White	Male	0	0	14	United-States	<= 50K									
Row11631	20		Private	107658	Some-coll...	10		Never-married	Tech-support	Not-in-family	White	Female	0	0	10	United-States	<= 50K									
Row15059	21		Private	243368	Preschool	1		Never-married	Farming-fishing	Not-in-family	White	Male	0	0	50	Mexico	<= 50K									

Шаг 2: Группировка похожих по смыслу значений у категориальных признаков

- Если номинальные признаки содержат большое количество различных категорий, то для снижения сложности модели и увеличения быстродействия процесса обучения можно выполнить группировку похожих по смыслу категорий. Как правило, такие категории являются наименее представительными по сравнению с другими категориями рассматриваемого признака.
- В исследуемом наборе данных есть два признака, к которым можно применить данный трюк: Workclass и Education.


Атрибут
Workclass



Категории
до преобразования:

- Private
- Self-emp-not-inc
- Self-emp-inc


- Local-gov
- State-gov
- Federal-gov
- Without-pay



Категории
после преобразования:

- Private
- Self-emp
- Gov
- Without-pay

Атрибут
Education




- Preschool
- 1st-4th
- 5th-6th
- 7th-8th
- 9th
- 10th
- 11th
- 12th

- Prof-school
- HS-grad
- Some-college
- Assoc-voc
- Assoc-acdm
- Doctorate
- Bachelors
- Masters



- No-school
- Prof-school
- HS-grad
- College
- Doctorate
- Bachelors
- Masters


Шаг 2: Группировка похожих по смыслу значений у атрибута Workclass




Выполните группировку похожих по смыслу значений у атрибута Workclass с помощью следующих команд:

```
$Workclass$ IN ("Self-emp-not-inc","Self-emp-inc") => "Self-emp"
$Workclass$ IN ("Local-gov","Federal-gov","State-gov") => "Gov"
$Workclass$ IN ("Private") => "Private"
$Workclass$ IN ("Without-pay") => "Without-pay"
```

Установите в качестве Replace Column Workclass, чтобы столбец обновился и содержал новые значения.




Шаг 2: Группировка похожих по смыслу значений у атрибута Education



Выполните группировку похожих по смыслу значений атрибута Education с помощью следующих команд:

```
$Education$ IN ("Preschool", "1st-4th", "5th-6th", "7th-8th", "9th", "10th", "11th", "12th") => "No-school"
$Education$ IN ("Some-college", "Assoc-voc", "Assoc-acdm") => "College"
$Education$ = "HS-grad" => "HS-grad"
$Education$ = "Bachelors" => "Bachelors"
$Education$ = "Masters" => "Masters"
$Education$ = "Prof-school" => "Prof-school"
$Education$ = "Doctorate" => "Doctorate"
```


Установите в качестве Replace Column Education.



Шаг 2: Удаление избыточных атрибутов


- Просмотрев и изучив семантику атрибутов, даже без проведения корреляционного анализа можно заметить, что набор данных содержит избыточные атрибуты. К таким атрибутам можно отнести следующие:
 - атрибут **Education-num**, имеющий семантическое сходство с атрибутом **Education**;
 - атрибут **Fnlwgt**, не влияющий на доход **Outcome**;
 - атрибут **Relationship**, содержащий информацию, которая частично может быть получена из данных о поле **Sex** и семейном положении **Marital-status**.
- Чтобы снизить сложность модели и сократить время, затрачиваемое на ее обучение, избыточные атрибуты удаляются.

Age	Workclass	Fnlwgt	Education	Educ ation- num	Marital- status	Occupation	Relationship	Race	Sex	Capit al- gain	Capit al- loss	Hours- per- week	Country	Outcome
39	State-gov	77516	Bachelors	13	Never-married	Adm-clerical	Not-in-family	White	Male	2174	0	40	United-States	<=50K
50	Self-emp-not-inc	83311	Bachelors	13	Married-civ-spouse	Exec-managerial	Husband	White	Male	0	0	13	United-States	<=50K




Age	Workclass	Education	Occupation	Relationship	Race	Capit al- gain	Capit al- loss	Hours- per- week	Country	Outcome
39	State-gov	Bachelors	Adm-clerical	Not-in-family	White	2174	0	40	United-States	<=50K
50	Self-emp-not-inc	Bachelors	Exec-managerial	Husband	White	0	0	13	United-States	<=50K

Шаг 2: Удаление избыточных атрибутов





Исключите из дальнейшего анализа атрибуты:

- Fnlwgt;
- Education-num;
- Marital-status;
- Sex.





Шаг 2: Предобработка тестовой выборки



Проделайте такие же шаги предварительной обработки для тестовой выборки, что и для обучающей. Название файла, где хранится тестовая выборка, *adult_test.csv*. Входные параметры в узлах должны совпадать с параметрами узлов, применяемых для обучающей выборки.

Шаг 3: Построение дерева решений



Для построения дерева решений установите следующие гиперпараметры:

- Class column = Outcome (признак, содержащий классы)
- Quality measure = Gini index (мера оценки доли примесей в узле дерева решений)
- Pruning method = MDL (метод, позволяющий не переобучать модель)
- Min number records per node = 2 (ограничение на минимальное количество объектов в листе дерева)
- Binary nominal splits = False (n -арное разбиение категориальных признаков)
- Остальные значения гиперпараметров по умолчанию

Шаг 3: Визуализация дерева решений

Column Filter

Удаление избыточных атрибутов

Decision Tree Learner

Обучение дерева решений

Decision Tree Predictor

Классификация объектов тестовой выборки

Decision Tree View (JavaScript)

Визуализация дерева решений

15

Dialog - 5:73 - Decision Tree View (JavaScript) (Визуализация)

15

Выполните визуализацию дерева решений, не меняя значений у параметров.

Построенное дерево решений

<=50K (22633/30139)		
▼Table:		
Category	%	n
<=50K	75.1	22633
>50K	24.9	7506
Total	100.0	30139

Relationship ⊖

= Not-in-family

<=50K (6891/7714)

►Table:

Capital-gain ⊕

= Bachelors

>50K (1582/2300)

►Table:

Capital-gain ⊕

= HS-grad

<=50K (2761/4055)

►Table:

Capital-gain ⊕

= No-school

<=50K (1187/1358)

►Table:

Capital-gain ⊕

= Husband

<=50K (6780/12457)

►Table:

Education ⊖

= Masters

>50K (647/831)

►Table:

Occupation ⊕

= College

<=50K (1840/3314)

►Table:

Capital-gain ⊕

= Doctorate

>50K (200/239)

►Table:

Capital-gain ⊕

= Prof-school

>50K (309/360)

►Table:

Capital-gain ⊕

= Wife

<=50K (712/1406)

►Table:

Occupation ⊕

= College

<=50K (1840/3314)

►Table:

Capital-gain ⊕

= Doctorate

>50K (200/239)

►Table:

Capital-gain ⊕

= Own-child

<=50K (4398/4462)

►Table:

Capital-gain ⊕

= Prof-school

>50K (309/360)

►Table:

Capital-gain ⊕

= Unmarried

<=50K (2998/3211)

►Table:

Capital-gain ⊕

= Prof-school

>50K (309/360)

►Table:

Capital-gain ⊕

= Other-relative

<=50K (854/889)

►Table:

Capital-gain ⊖

≤ 5974.00

<=50K (853/881)

►Table:

Capital-gain ⊖

> 5974.00

>50K (7/8)

►Table:



Capital-gain ⊖

© Я.А. Краева

Машинное обучение: как найти то, что скрыто в данных


21/25

Шаг 3: Классификация объектов тестовой выборки



Измените название целевой переменной, спрогнозированной деревом решений, на Predicted outcome.



Шаг 4: Вычисление метрик точности




Оцените точность дерева решений, вычислив метрики точности. Установите в качестве First Column (столбец с истинными метками классов) переменную Outcome и в качестве Second Column – Predicted outcome.

Отобразите матрицу с вычисленными метриками точности, установив следующие параметры:


- Includes: Metric value (включение столбца со значениями метрик)
- Show row number (отображение столбца с порядковыми номерами метрик)
- Show RowIDs (отображение столбца с названиями метрик)



Шаг 5: Запись полученных результатов



Для сохранения результатов создайте пустой csv-файл *adult_results.csv* и укажите путь до этого файла.



Для экспорта результатов в csv-файл установите параметры:

- Column delimiter: , (разделитель столбцов)
- Row delimiter: System default (разделитель строк)
- Write column header (записываются названия столбцов в выходной файл)
- Write RowID (исключается столбец с порядковыми номерами объектов из записи в выходной файл)

Шаг 6: Сдача практической работы

- После того, как пройдены все шаги и реализован поток данных, выполните экспорт получившегося потока работ из KNIME и прикрепите его в электронный ЮУрГУ в качестве ответа на задание



Практика 4. Разбор задачи (классификация)