

Машинное обучение: как найти то, что скрыто в данных?

Кластеризация

Задача «Сегментация клиентов»



Постановка задачи и данные

- **Задача:** сегментировать клиентов компании Starbucks для улучшения рекламных стратегий
- **Входные данные:**
 - данные о поведении клиентов на различные рекламные предложения за месяц
 - данные представлены в трех таблицах:
 1. *portfolio.csv* (10 предложений × 6 атрибутов): описывает детали рекламных предложений;
 2. *profile.csv* (17 000 клиентов × 5 атрибутов): содержит демографические данные о клиентах;
 3. *transcript.csv* (306 534 событий × 4 атрибута): содержит историю событий для каждого клиента: получение, просмотр или выполнение рекламного предложения, а также транзакции



* <https://www.kaggle.com/datasets/ihormuliar/starbucks-customer-data/>

Данные

Рекламные предложения

portfolio	
PK	<u>id</u>
	offer_type
	difficulty
	reward
	duration
	channels

История транзакций

transcript	
PK	<u>id</u>
FK	person
FK	event
	time
	value

Клиенты

profile	
PK	<u>id</u>
	gender
	age
	became_member_on
	income


- *id* – идентификатор предложения
- *offer_type* – тип предложения
- *difficulty* – min сумма покупки для активации предложения
- *reward* – вознаграждение
- *duration* – срок действия предложения
- *channels* – способы отправки рекламы

- *id* – идентификатор события
- *event* – тип события
- *person* – идентификатор клиента
- *time* – время события в часах с начала отправки рекламы
- *value* – id предложения или сумма транзакции в зависимости от типа записи

- *id* – идентификатор клиента
- *gender* – пол клиента
- *age* – возраст клиента
- *became_member_on* – дата регистрации клиента
- *income* – годовой доход

Данные

- Для сегментации клиентов на основе трех исходных таблиц был сформирован набор данных *customer_behavior.csv*, состоящий из 14 825 объектов




Данные


- csv-файл *customer_behavior.csv*

<i>person</i>	<i>num_receiv</i>	<i>num_view</i>	<i>num_compl</i>	<i>num_trans</i>	<i>money_spent</i>
0009655...	5	4	3	8	127.6
0011e0d...	5	5	3	5	79.46
0020c2b...	5	3	3	8	196.86
0020ccb...	4	4	3	12	154.05
003d66b...	5	4	3	18	48.34
00426fe...	5	2	1	17	68.51

Этапы решения задачи кластеризации



Поток работ



Шаг 1: Считывание набора данных



Dialog - 4:1 - CSV Reader (Чтение)

File

Settings Transformation Advanced Settings Limit Rows Encoding Flow Variables Job Manager Selection Memory Policy

Input location

Read from Local File System

Mode File Files in folder

File D:\Данные\Лекции по машинному обучению\Практики\Практика 4\customer_behavior.csv Browse...

Reader options

Format

Autodetect format

Column delimiter , Row delimiter Line break Custom \n

Quote char Quote escape char

Comment char #

Has column header Has RowID

Support short data rows Prepend file index to RowID

Preview

The suggested column types are based on the first 10000 rows only. See 'Advanced Settings' tab.

Row ID	person	num_re...	num_vi...	num_co...	num_tr...	money...
Row0	0009655768c64bdeb2e877511632db8f	5	4	3	8	127.6
Row1	0011e0d4e6b944f998e987f904e8c1e5	5	5	3	5	79.46
Row2	0020c2b971eb4e9188eac86d93036a77	5	3	3	8	196.86
Row3	0020ccb6b6d84e358d3414a3ff76cffd	4	4	3	12	154.05
Row4	003d66b6608740288d6cc97a6903f4f0	5	4	3	18	48.34
Row5	00426fe3ffde4c6b9cb9ad6d077a13ea	5	2	1	17	68.51
Row6	004b041fbfe44859945daa2c7f79ee64	3	2	2	6	138.36
Row7	004c5799adb42868b9c9ff0396190900	5	4	5	12	347.38
Row8	005500a7188546ff8a767329a2f7c76a	5	3	1	4	20.36
Row9	0056df74b63b4298809f0b375a304cf4	4	3	3	5	144.14
Row10	00715b6e55c3431cb56ff7307eb19675	6	3	5	15	375.12
Row11	0082fd87c18f45f2be70dbcb0fb8aad	5	4	2	7	121.85
Row12	00840a2ca5d2408e982d56544dc14ffd	6	2	3	17	62.93
Row13	00857b24b13f4fe0ad17b605f00357f5	5	3	?	4	6.26
Row14	008d7088107b468893889da0ede0df5c	6	5	?	7	16.18
Row15	0091d2b6a5ea4defaa8393e4e816db60	5	5	4	12	279.16
Row16	0099bf30e4cb4265875266eb3eb25eab	5	3	2	9	105.83
Row17	00a794f62b9a48beb58f8f6c02c2f1a6	5	5	1	11	166.4
Row18	00ae03011f9f49b8a4b3e6d416678b0b	6	5	4	8	218.05
Row19	00aee28bbb3848dd8a31f0c91dc267dd	3	2	?	5	20.53
Row20	00b18b535d6d4f779dea4dc9ac451478	5	5	3	5	133.25
Row21	00b3400e4ff64ee68ce9ada1d0c222f0	5	2	3	10	163.92
Row22	00b3c376db2a4115af3aef34a02f61d6	3	2	3	8	219.63

OK Apply Cancel ?

- Выберите из директории файл, в котором хранится набор данных *customer_behavior.csv*
- Установите параметры, необходимые для верного считывания данного csv-файла:
 - Column delimiter: , (разделитель столбцов)
 - Row delimiter: line break (разделитель строк)
 - Has column header (считываются данные с названиями столбцов)
 - Значения остальных параметров оставьте по умолчанию
- Проверьте, что загруженные данные из файла отображаются в представленном виде

Шаг 2: Проведение статистического анализа и визуализация

- Выполним предварительную обработку данных для дальнейшего анализа. Для этого сначала изучим исходные данные: посчитаем статистические показатели по каждому признаку.

Statistics View

2

Визуализация статистических показателей

CSV Reader

Чтение набора данных

Dialog - 3:46 - Statistics View (Визуализация)

Statistics

Rows: 6 | Columns: 14

2

Name	Type	# Missing val...	# Unique val...	Minimum	Maximum	25%
person	String	0	14825	①	②	③
num_received	Number (inte...	5	6	1	6	4
num_viewed	Number (inte...	150	6	1	6	3
num_complet...	Number (inte...	2839	6	1	6	2
num_transact...	Number (inte...	333	34	1	36	5
money_spent	Number (dou...	333	12379	0.15	1,608.69	34.163

Data

Selected Columns

Manual Wildcard Regex Type

Search Aa

Excludes

Includes

person
num_received
num_viewed
num_completed
num_transactio...
money_spent

Displayed Statistics

Excludes

Includes

1% Quantile
5% Quantile
10% Quantile
90% Quantile
95% Quantile
99% Quantile
Variance

Name
Type
Missing va...
Unique val...
Minimum
Maximum
25% Quantile

View

Title

Cancel Ok

Постройте и отобразите матрицу со статистическими показателями признаков. Для этого включите *все* признаки исходного набора данных.

В качестве статистических показателей оставьте те, которые указаны по умолчанию:

- Type (тип данных)
- # Missing values (кол-во пропусков)
- # Unique values (кол-во уникальных значений)
- Min, max (минимум, максимум)
- 25%, 50%, 75% quantile (первый–третий квантили)
- Mean (среднее значений)
- Mean absolute deviation, Standard deviation (среднее абсолютное и стандартное отклонения)
- Sum (сумма)
- 10 most common values (10 самых часто встречающихся значений)


Шаг 2: Замена пропусков

Interactive View: Statistics View

Statistics

Rows: 6 | Columns: 14

Name	Type	# Missing val...	# Unique val...	Minimum	Maximum	25% Qu...
person	String	0	14825	?	?	?
num_received	Number (inte...	5	6	1	6	4
num_viewed	Number (inte...	150	6	1	6	3
num_complet...	Number (inte...	2839	6	1	6	2
num_transact...	Number (inte...	333	34	1	36	5
money_spent	Number (dou...	333	12379	0.15	1,608.69	34.163



Dialog - 3:49 - Missing Value (Замена)

3

File

Default Column Settings Flow Variables Job Manager Selection Memory Policy

Column Search

Filter Options

None

person

num_received

num_viewed

num_completed

num_transactions

money_spent

Remove

Fix Value

Value 0

Remove

Fix Value

Value 0

Remove

Fix Value

Value 0

Remove

Fix Value

Value 0,0


Add

OK Apply Cancel ?

- Статистический анализ показал, что все атрибуты (кроме person) содержат пропущенные значения (см. таблицу Statistics). Поскольку алгоритмы кластеризации не могут работать с данными с пропусками, то необходимо применить один из существующих способов их обработки.
- В данной задаче пропущенные значения у всех признаков будем заменять на нули.

Откройте вкладку Column setting и из списка признаков выберите все, кроме person. Далее в качестве способа заполнения пропущенных значений укажите Fix value, для которого установите значение 0.

Шаг 2: Построение и визуализация диаграммы размаха




- Поскольку алгоритм k -means не устойчив к шумам, то необходимо установить, имеются ли они в исходных данных. Для этого проведем графический анализ на основе диаграмм размаха.

Постройте диаграммы размаха для каждого из пяти вещественных признаков, включив их в соответствующее окно: num_received, num_viewed, num_completed, num_transactions, money_spent.

- Диаграмма размаха для money_spent показывает, что большинство клиентов потратили на покупки в Starbucks в течение месяца от 30 \$ до 165 \$. При этом клиенты с большей тратой, от 350 \$, считаются выбросами.
- Диаграммы размаха для остальных признаков показывают, что признаки имеют равномерное или нормальное распределения, поэтому в них отсутствует большое число выбросов и нет необходимости в их удалении.

Шаг 2: Удаление выбросов



Удалите объекты из набора данных, которые содержат аномальные значения у признака `money_spent`. Для этого выберите в списке этот признак.

Установите для параметров, используемых при нахождении выбросов, следующие значения:

- Interquartile range multiplier (k): 1.5
- Apply to: all outliers
- Treatment option: Remove outlier rows

В результате выполнения узла Numeric Outliers была автоматически построена таблица, в которой можно ознакомиться с количеством найденных выбросов у признака `money_spent`.

The 'Summary - 3:50 - Numeric Outliers (Удаление)' window shows the results of the outlier removal process. It displays a table with 5 columns: 'Row ID', 'Outlier ...', 'Membe...', 'Outlier ...', 'Lower ...', and 'Upper ...'. The table has 1 row, 'Row0', with the following values: 'money_spent', 14825, 472, -162.736, and 355.074. The 'Outlier ...' column is highlighted with a red box.

Row ID	Outlier ...	Membe...	Outlier ...	Lower ...	Upper ...
Row0	money_spent	14825	472	-162.736	355.074

После удаления объектов-выбросов **размер выборки** стал составлять **14 353** вместо 14 825.

Шаг 2: Масштабирование признаков

- Для уравнивания важности признаков, помимо min-max масштабирования, используют z-нормализацию.


- Недостатком min-max масштабирования является чувствительность к выбросам: они расширяют диапазон, сжимая основные значения в узком интервале у нуля.

- Z-нормализация (z-normalization)** – процесс приведения каждого признака X_i в наборе данных X , $0 \leq i < d$, к некоторому диапазону на основе его среднего значения и стандартного отклонения:


$$X_{norm_i} = \frac{X_i - \mu_i}{\sigma_i},$$

$$\mu_i = \frac{1}{\ell} \sum_{j=0}^{\ell-1} x_i^{(j)}, \quad \sigma_i = \sqrt{\frac{1}{\ell} \sum_{j=0}^{\ell-1} (x_i^{(j)} - \mu_i)^2},$$

где μ_i и σ_i – среднее арифметическое и стандартное отклонение признака X_i соответственно.




Выберите все признаки обучающей выборки для их масштабирования.




В качестве метода масштабирования выберите Z-score



Шаг 3: Нахождение оптимального числа кластеров методом локтя



- Для нахождения оптимального числа кластеров будем использовать метод локтя.
- Данный метод заключается в многократном циклическом выполнении алгоритма k -means и измерении суммы квадратов внутрикластерных расстояний (WCSS) с увеличением количества кластеров.
- В качестве оптимального количества кластеров выбирается тот вариант, при котором данное расстояние перестанет существенно уменьшаться.



Шаг 3: Нахождение оптимального числа кластеров методом локтя




- Поскольку в методе локтя реализуется проход по всем значениям k из заданного диапазона $[start_k, end_k]$, то сначала необходимо определить начало цикла, задав для его выполнения начальное и конечное значения диапазона числа кластеров.


Установите следующие значения параметров для выполнения итераций цикла по k :

- From: 2 (начальное значение счетчика)
- To: 10 (конечное значение счетчика)
- Step: 1 (шаг счетчика)
- Loop variable is: integer (тип данных счетчика)


Шаг 3: Нахождение оптимального числа кластеров методом локтя




Шаг 3: Нахождение оптимального числа кластеров методом локтя




Шаг 3: Нахождение оптимального числа кластеров методом локтя




Шаг 3: Нахождение оптимального числа кластеров методом локтя





Шаг 3: Нахождение оптимального числа кластеров методом локтя




Шаг 3: Нахождение оптимального числа кластеров методом локтя




Шаг 4: Кластеризация данных



Далее выполните кластеризацию данных k -means при $k_{opt} = 5$. Для этого явно задайте гиперпараметр number of clusters значением 5. После кластеризации для приведения признаков к исходным значениям выполните их демасштабирование. Все параметры оставьте по умолчанию.



Шаг 4: Кластеризация данных



Отобразите полученные результаты кластеризации. Для этого сначала выполните окрашивание объектов в соответствии с их принадлежностью к кластеру. Выберите наиболее предпочтительную палитру цветов и установите признак Cluster, которому будут присваиваться цвета.

Шаг 4: Интерпретация результатов кластеризации данных

- Далее выполним анализ полученных результатов: выявим отличительные характеристики поведения клиентов для каждого кластера. Это поможет установить, какие лучше всего отправлять рекламные предложения тому или иному клиенту, и в целом обозначить стратегии для дальнейшей работы с клиентами.
- Определим следующие интересующие ключевые показатели:

1. *частота* – количество совершенных транзакций, сделанных клиентом в течение месяца

$$frequency = num_transactions ;$$

2. *средняя стоимость покупки* – средняя сумма транзакции

$$avg_purchase_value = \frac{money_spent}{num_transactions} ;$$


3. *доля «эффективных» рекламных предложений* – доля рекламных предложений, на которые отреагировал клиент, совершив некоторую покупку, относительно всех отправленных ему предложений

$$offer_complete_rate = \frac{num_completed}{num_received} ;$$


4. *чувствительность к рекламным предложениям* – доля транзакций, совершенных клиентом под влиянием рекламных предложений

$$offer_sensitivity = \frac{num_completed}{num_transactions} .$$


Шаг 4: Интерпретация результатов кластеризации данных



Сначала вычислите средние значения показателей `num_received`, `num_viewed`, `num_completed`, `num_transactions`, `money_spent` по каждому кластеру. Для этого во вкладке `Manual Aggregation` выберите соответствующие столбцы и установите в качестве агрегирующей функции `Mean`. Названия новых столбцов со средними значениями должны быть сформированы как `Aggregation method (column name)`.




Шаг 4: Интерпретация результатов кластеризации данных




Для вычисления ключевых показателей создайте 4 новых столбца с названиями `frequency`, `avg_purchase_value`, `offer_complete_rate`, `offer_sensitivity`. При создании этих столбцов впишите следующие формулы для нахождения их значений:

- `column("Mean(num_transactions)")`
- `column("Mean(money_spent)") / column("Mean(num_transactions)")`
- `column("Mean(num_completed)") / column("Mean(num_received)")`
- `column("Mean(num_completed)") / column("Mean(num_transactions)")`





Перед использованием блока **Column Expressions** необходимо установить расширение **KNIME Column Expressions (Labs)**. Для этого выберите «File» > «Install KNIME Extensions».

Шаг 4: Интерпретация результатов кластеризации данных




Исключите из дальнейшего анализа *неключевые* показатели из таблицы и отобразите ее. Установите такие же значения параметров, как на рисунках.



Шаг 4: Интерпретация результатов кластеризации данных

- Присвоим название каждому кластеру в зависимости от поведенческих особенностей клиентов.
- Для этого была сформирована таблица, в которой для каждого ключевого показателя каждого кластера определена категория (**высокий**, **средний** или **низкий**), основанная на результатах кластеризации данных.

Interactive View: Table View				
Table View				
Rows: 5 Columns: 5				
☐ Cluster String	Frequency Number (double)	Avg_purchase Number (double)	Offer_complete_r... Number (double)	Offer_sensitivity Number (double)
☐ cluster_0	6.573	16.958	0.634	0.479
☐ cluster_1	17.033	4.3	0.434	0.121
☐ cluster_2	12.518	18.057	0.804	0.317
☐ cluster_3	6.284	12.408	0.421	0.211
☐ cluster_4	4.363	5.759	0.118	0.132




Сегмент клиентов	<i>frequency</i>	<i>avg_purchase_value</i>	<i>offer_complete_rate</i>	<i>offer_sensitivity</i>
Наиболее ценные клиенты (кластер 2)	высокий	высокий	высокий	средний
Постоянные клиенты (кластер 1)	высокий	низкий	низкий	низкий
Клиенты с высоким потенциалом (кластер 0)	средний	высокий	средний	высокий
Клиенты-просмотрщики рекламы (кластер 3)	низкий	средний	низкий	средний
Неактивные клиенты (кластер 4)	низкий	низкий	низкий	низкий


Шаг 4: Интерпретация результатов кластеризации данных

Сегмент клиентов	Рекомендации
Наиболее ценные клиенты (кластер 2)	Компания должна сделать все возможное, чтобы удержать этих клиентов и попытаться привлечь их, чтобы они совершили больше покупок, имеющих более высокую среднюю стоимость.
Постоянные клиенты (кластер 1)	Постоянные клиенты совершают покупки как под воздействием рекламы, так и без нее. Компании следует удержать этих клиентов и попытаться увеличить количество покупок, средняя стоимость которых выше средней. Возможно, нужно давать им попробовать более дорогие продукты бесплатно или по сниженной цене, чтобы это приводило к большим тратам.
Клиенты с высоким потенциалом (кластер 0)	Эти клиенты имеют высокий потенциал стать самыми ценными клиентами, если их частота покупок увеличится. Поскольку их чувствительность и реакция на рекламные предложения относительно высоки, компания должна отправлять им больше предложений, чтобы они совершали больше покупок, что, в свою очередь, повысит их лояльность к компании.
Клиенты-просмотрщики рекламы (кластер 3)	Эти клиенты любят только просматривать предложения. Возможно, нужно отправлять им больше рекламы с действительно выгодными предложениями на различные продукты, чтобы привлечь их покупать и вырабатывать у них привычку регулярного посещения кофеен.
Неактивные клиенты (кластер 4)	Данные клиенты не проявляют особой активности, либо потому что они являются лояльными клиентами других компаний, либо у них нет привычки покупать горячие напитки вне дома. Компании необходимо инвестировать больше ресурсов, если они хотят изменить текущую ситуацию.

Шаг 5: Запись полученных результатов



Для сохранения результатов создайте пустой csv-файл *customer_behavior_results.csv* и укажите путь до этого файла.



Для экспорта результатов в csv-файл установите параметры:

- Column delimiter: , (разделитель столбцов)
- Row delimiter: System default (разделитель строк)
- Write column header (записываются названия столбцов в выходной файл)
- Write RowID (исключается столбец с порядковыми номерами объектов из записи в выходной файл)

Шаг 6: Сдача практической работы

- После того, как пройдены все шаги и реализован поток данных, выполните экспорт получившегося потока работ из KNIME и прикрепите его в электронный ЮУрГУ в качестве ответа на задание



Практика 5. Разбор задачи (кластеризация)