


Машинное обучение: как найти то, что скрыто в данных?

Поиск шаблонов



*Мыслить по шаблону –
вернейший способ завалить дело.
Дж.Ф. Энрайт*

Содержание

- Частые наборы и шаблоны
- Алгоритм Apriori поиска частых наборов


Содержание

- **Частые наборы и шаблоны**
- Алгоритм Apriori поиска частых наборов

Пример задачи


- **Задача:** определить наборы товаров, которые часто покупают совместно в супермаркете
- **Данные:** история транзакций, каждая из которых содержит перечень товаров, купленных клиентом супермаркета за один визит.

BillNo	Itemname	Quantity	Date	Price	CustomerID	Country
536365	WHITE HANGING HEART T-LIGHT HOLDER	6	01.12.10 08:26	2.55	17850	United Kingdom
536365	WHITE METAL LANTERN	6	01.12.10 08:26	3.39	17850	United Kingdom
536365	CREAM CUPID HEARTS COAT HANGER	8	01.12.10 08:26	2.75	17850	United Kingdom
536365	KNITTED UNION FLAG HOT WATER BOTTLE	6	01.12.10 08:26	3.39	17850	United Kingdom
536365	RED WOOLLY HOTTIE WHITE HEART	6	01.12.10 08:26	3.39	17850	United Kingdom




- <https://www.kaggle.com/datasets/aslanahmedov/market-basket-analysis>

Частый набор vs шаблон



Частые k -наборы
 $1 \leq k \leq k_{max}$




Шаблоны (ассоциативные правила)
антецедент $\rightarrow$ *консеквент*

ЕСЛИ		ТО	
	 		
	 		 

Объекты, наборы, транзакции

- **Объекты («товары»)**
 - кола, молоко, вода, яблоки, хлеб, яйца
- **Наборы**
 - (вода), ...,
 - (молоко, хлеб), ...,
 - (кола, молоко, хлеб), ...,
 - (кола, вода, хлеб, яйца), ...,
 - ...
- **Транзакции («корзины»)**


TID	Транзакция
1	молоко, хлеб
2	вода, яблоки, хлеб, яйца
3	кола, молоко, вода, яблоки
4	молоко, вода, яблоки, хлеб
5	кола, молоко, яблоки, хлеб
6	хлеб, яйца
7	молоко, хлеб, яйца
8	молоко, вода, яблоки
9	молоко, яблоки, хлеб, яйца
10	вода, яблоки



Шаблон

- **Шаблон $A \rightarrow B$**
(если купил A , то купит B)
 - $A \neq \emptyset, B \neq \emptyset A \cap B = \emptyset$
- **Правильно**
 - вода $\rightarrow$ яблоки
 - (молоко, хлеб) $\rightarrow$ яйца
 - яйца $\rightarrow$ (молоко, хлеб)
 - (молоко, хлеб, яйца) $\rightarrow$ (кола, вода)
- **Неправильно**
 - вода $\rightarrow$?
 - ? $\rightarrow$ молоко
 - вода $\rightarrow$ вода
 - (молоко, хлеб) $\rightarrow$ (кола, хлеб)

TID	Транзакция
1	молоко, хлеб
2	вода, яблоки, хлеб, яйца
3	кола, молоко, вода, яблоки
4	молоко, вода, яблоки, хлеб
5	кола, молоко, яблоки, хлеб
6	хлеб, яйца
7	молоко, хлеб, яйца
8	молоко, вода, яблоки
9	молоко, яблоки, хлеб, яйца
10	вода, яблоки




Поддержка и достоверность шаблона

- Поддержка
- Достоверность

$$\text{sup}(\textcolor{brown}{A} \rightarrow \textcolor{teal}{B}) = P(\textcolor{teal}{A} \cup \textcolor{teal}{B})$$


$$\text{conf}(\textcolor{brown}{A} \rightarrow \textcolor{teal}{B}) = P(B|A) = \frac{\text{sup}(\textcolor{teal}{A} \cup \textcolor{teal}{B})}{\text{sup}(\textcolor{brown}{A})}$$



Поддержка и достоверность шаблона

- Поддержка:
$$\text{sup}(\textcolor{brown}{A} \rightarrow \textcolor{teal}{B}) = P(\textcolor{teal}{A} \cup \textcolor{teal}{B})$$
- Достоверность:
$$\text{conf}(\textcolor{brown}{A} \rightarrow \textcolor{teal}{B}) = P(B|A)$$
- Пример: $\{\textcolor{brown}{\text{молоко}}, \textcolor{brown}{\text{хлеб}}\} \rightarrow \textcolor{teal}{\text{яйца}}$
 - $\text{sup} = \frac{2}{10} = 0.2$
 - $\text{conf} = \frac{2}{5} = 0.4$

TID	Транзакция
1	молоко , хлеб
2	вода, яблоки, хлеб, яйца
3	кола, молоко, вода, яблоки
4	молоко , вода, яблоки, хлеб
5	кола, молоко , яблоки, хлеб
6	хлеб, яйца
7	молоко , хлеб , яйца
8	молоко, вода, яблоки
9	молоко , яблоки, хлеб , яйца
10	вода, яблоки



Частый набор

- *minsup* – порог поддержки (параметр)
- Набор *I* является **частым**, если его поддержка не ниже порога поддержки:
$$\text{sup}(I) \geq \text{minsup}$$
- Множество всех частых наборов: $\mathcal{L} = \bigcup_{k=1}^{k_{\max}} \mathcal{L}_k$,
 $\mathcal{L}_k$ – множество частых *k*-наборов

Частый набор

$minsup = 0.6$

$\mathcal{L}_1 = \{\{\text{молоко}\}, \{\text{яблоки}\}, \{\text{хлеб}\}\}$


$minsup = 0.5$

$\mathcal{L}_1 = \{\{\text{молоко}\}, \{\text{яблоки}\}, \{\text{хлеб}\}\}$

$\mathcal{L}_2 = \left\{ \begin{array}{l} \{\text{вода, яблоки}\}, \\ \{\text{молоко, хлеб}\}, \\ \{\text{молоко, яблоки}\} \end{array} \right\}$

- Чем больше $minsup$, тем меньше частых наборов

TID	Транзакция
1	молоко, хлеб
2	вода, яблоки, хлеб, яйца
3	кола, молоко, вода, яблоки
4	молоко, вода, яблоки, хлеб
5	кола, молоко, яблоки, хлеб
6	хлеб, яйца
7	молоко, хлеб, яйца
8	молоко, вода, яблоки
9	молоко, яблоки, хлеб, яйца
10	вода, яблоки




Устойчивый шаблон

- $minconf$ – порог достоверности (параметр)
- Шаблон $A \rightarrow B$ **устойчив**, если его поддержка и достоверность не ниже пороговых значений:

$$\text{sup}(A \rightarrow B) \geq \text{minsup} \wedge \text{conf}(A \rightarrow B) \geq \text{minconf}$$

Поиск шаблонов: полный перебор

1. Сгенерируем все кандидаты в устойчивые шаблоны
 2. Вычислим sup и conf для каждого кандидата
 3. Отбросим кандидаты в устойчивые шаблоны с $\text{sup} < \text{minsup}$, $\text{conf} < \text{minconf}$
- $|\mathcal{R}| = \sum_{k=1}^{m-1} \left[C_k^m \cdot \sum_{i=1}^{m-k} C_i^{m-k} \right] = 3^m - 2^{m+1} + 1$



m	$ \mathcal{R} $
6	602
10	57 002

Поиск устойчивых шаблонов
полным перебором
вычислительно невозможен

Поиск шаблонов: идеи

TID	Транзакция
1	молоко, хлеб
2	вода, яблоки, хлеб, яйца
3	кола, молоко, вода, яблоки
4	молоко, вода, яблоки, хлеб
5	кола, молоко, яблоки, хлеб

$\{\text{молоко, яблоки}\} \rightarrow \{\text{вода}\} (s = 0.4, c = 0.67)$

$\{\text{молоко, вода}\} \rightarrow \{\text{яблоки}\} (s = 0.4, c = 1.0)$

$\{\text{яблоки, вода}\} \rightarrow \{\text{молоко}\} (s = 0.4, c = 0.67)$

$\{\text{вода}\} \rightarrow \{\text{молоко, яблоки}\} (s = 0.4, c = 0.67)$

$\{\text{яблоки}\} \rightarrow \{\text{молоко, вода}\} (s = 0.4, c = 0.5)$

$\{\text{молоко}\} \rightarrow \{\text{яблоки, вода}\} (s = 0.4, c = 0.5)$

- Шаблоны примера – разбиения одного набора
- Разбиения одного набора имеют равную поддержку, но могут иметь разную достоверность
- Для поиска шаблонов обработку поддержки и достоверности можно отделить друг от друга

Поиск шаблонов: алгоритм

1. Сгенерируем всех кандидатов в частые наборы
2. Вычислим их поддержку и найдем все частые наборы с поддержкой не ниже *minsup*
3. Сгенерируем шаблоны, выполняя разбиение каждого частого набора; устойчивыми будут шаблоны с достоверностью не ниже *minconf*

Поиск шаблонов: алгоритм

1. Сгенерируем всех кандидатов в частые наборы

2. Вычислим их поддержку и найдем все частые наборы с поддержкой не ниже $minsup$

3. Сгенерируем шаблоны, выполняя разбиение каждого частого набора; устойчивыми будут шаблоны с достоверностью не ниже $minconf$


Полный перебор

1			2
2	 	 	4
3	  	    	8
...		...	...
m			2^m

Поиск шаблонов: алгоритм

1. Сгенерируем всех кандидатов в частые наборы
2. Вычислим их поддержку и найдем все частые наборы с поддержкой не ниже *minsup*
3. Сгенерируем шаблоны, выполняя разбиение каждого частого набора; устойчивыми будут шаблоны с достоверностью не ниже *minconf*

Полный
перебор



Сокращение перебора: принцип Априори

- Поддержка набора всегда не больше поддержки любого его поднабора
- Наборы и их поддержка
 - $\text{sup}(\text{milk}) = 0.7$
 - $\text{sup}(\text{milk, beer}) = 0.4$
 - $\text{sup}(\text{milk, beer, fries}) = 0.2$
 - $\text{sup}(\text{milk, beer, fries, apple}) = 0.1$

1			
2			
3			
4			
5			
6			
7			
8			
9			 
10			

Сокращение перебора: принцип Априори

- Если набор частый,
то все его *поднаборы* частые
 - $\text{sup}(\text{milk, beer, fries}) = 0.2$
 - $\text{sup}(\text{milk, beer}) = 0.4$, $\text{sup}(\text{milk, fries}) = 0.4$, $\text{sup}(\text{beer, fries}) = 0.4$
 - $\text{sup}(\text{milk}) = 0.6$, $\text{sup}(\text{beer}) = 0.7$, $\text{sup}(\text{fries}) = 0.6$
- Если набор редкий,
то все его *наднаборы* редкие
 - $\text{sup}(\text{cabbage}) = 0.1$


$\text{minsup} = 0.2$

1			
2			
3			
4			
5			
6			
7			
8			
9			
10			


Содержание

- Частые наборы и шаблоны
- **Алгоритм Apriori поиска частых наборов**

Сокращение перебора: принцип Априори




Сокращение перебора: принцип Априори



 – редкий набор
 – заведомо редкий набор

Алгоритм Априори, шаг 1

- Генерация кандидатов в частые 1-наборы



- Подсчет поддержки, формирование множества частых 1-наборов


1		0.7
2		0.7
3		0.6
4		0.2
5		0.2

$minsup = 0.2$

1			
2			
3			
4			
5			
6			
7			
8			 
9			
10			

Алгоритм Априори, шаг 2

- Генерация кандидатов в частые 2-наборы:
декартово (прямое) произведение частых 1-наборов на себя



Алгоритм Априори, шаг 2

minsup = 0.2

- Подсчет поддержки, формирование множества частых 2-наборов


1		0.4
2		0.4
3		0.1
4		0.2
5		0.4

6		0.2
7		0.2
8		0
9		0.1
10		0

1		
2		
3		
4		
5		
6		
7		
8		
9		
10		

Алгоритм Априори, шаг 3

- Генерация кандидатов в частые 3-наборы: самосоединение частых 2-наборов



Алгоритм Априори, шаг 3

- Отбрасывание редких 3-наборов кандидатов



Принцип Априори

**Если набор частый,
то все его
поднаборы частые**

1		
2		
3		
4		
5		
6		

Алгоритм Априори, шаг 3

- Подсчет поддержки, формирование множества частых 3-наборов


1		0.2
2		0.2

$minsup = 0.2$

1				
2				
3				
4				
5				
6				
7				
8				
9				
10				

Алгоритм Априори, шаг 4

- Генерация кандидатов в частые 4-наборы




- Отбрасывание редких 4-наборов кандидатов

1		
---	---	--

- Конец обработки: нет наборов-кандидатов


Алгоритм Априори, результаты

 $minsup = 0.2$

1		0.7
2		0.7
3		0.6
4		0.2
5		0.2

6		0.4
7		0.4
8		0.2
9		0.4
10		0.2
11		0.2

12		0.2
13		0.2

1	
2	
3	
4	
5	
6	
7	
8	
9	
10	

Генерация шаблонов: пример

1	 	→		0.5
2	 	→		0.5
3	 	→		0.5
4		→	 	0.33
5		→	 	0.29
6		→	 	0.29

conf

$minsup = 0.2$
 $minconf = 0.5$

1	  
2	 
3	 
4	  
5	 
6	 
7	 
8	   
9	  
10	